

# Système de stockage distribué basé sur une DHT

Projet Master Systèmes et Applications Répartis (SAR)

PSAR – Sorbonne Université

**Auteurs:** Cedric Genevieve, Safa Gunes, Somaya Boudalil  
Étudiants en Master 2026 — Systèmes et Applications Répartis

**Instructeur:** Prof. Alessio Pagliari

**Date:** 15 avril 2026

---

## Table des matières

|          |                                                                                |           |
|----------|--------------------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Analyse Comparative des Paradigmes Architecturaux de Stockage Distribué</b> | <b>2</b>  |
| 1.1      | Étude des approches P2P structurée: Les DHTs . . . . .                         | 2         |
| 1.1.1    | Introduction au problème du Lookup . . . . .                                   | 2         |
| 1.1.2    | Comparaison des stratégies de recherche . . . . .                              | 3         |
| 1.1.3    | Fondamentaux des Distributed Hash Tables . . . . .                             | 5         |
| 1.1.4    | Mécanismes des DHTs . . . . .                                                  | 6         |
| 1.1.5    | Interfaces des DHTs . . . . .                                                  | 7         |
| 1.1.6    | Conclusions . . . . .                                                          | 7         |
| 1.2      | Étude de l'approche hiérarchisée : HBase . . . . .                             | 9         |
| 1.2.1    | Fondamentaux architecturaux de HBase . . . . .                                 | 9         |
| 1.2.2    | Mécanismes internes : partitionnement et gestion des pannes . . . . .          | 10        |
| 1.2.3    | Avantages et limites . . . . .                                                 | 10        |
| 1.3      | Conclusion et justification du choix architectural . . . . .                   | 10        |
| <b>2</b> | <b>Première génération : architecture centralisée inspirée de Napster</b>      | <b>12</b> |
| <b>3</b> | <b>Deuxième génération : architecture non structurée inspirée de Gnutella</b>  | <b>13</b> |
| 3.1      | Positionnement général et lien avec Gnutella . . . . .                         | 13        |
| 3.2      | Problème initial : l'absence de vue globale . . . . .                          | 13        |
| 3.3      | Passage à un mesh : ce que cela corrige, et ce que cela casse . . . . .        | 14        |
| 3.4      | Le flooding comme correction partielle . . . . .                               | 16        |
| 3.5      | Réponse directe, puis <i>reverse path caching</i> . . . . .                    | 18        |
| 3.6      | Usages réels et intérêt pratique . . . . .                                     | 19        |
| 3.7      | Bilan . . . . .                                                                | 20        |
| <b>4</b> | <b>Troisième génération : DHT structurée inspirée de Chord</b>                 | <b>21</b> |
| 4.1      | Chord . . . . .                                                                | 21        |
| 4.1.1    | Principe de fonctionnement . . . . .                                           | 21        |
| 4.1.2    | Routage efficace : Finger Table . . . . .                                      | 21        |
| 4.1.3    | Algorithmes essentiels . . . . .                                               | 21        |
| 4.1.4    | Complexité (résumé) . . . . .                                                  | 22        |
| 4.2      | Implémentation de Chord . . . . .                                              | 22        |

# 1 Analyse Comparative des Paradigmes Architecturaux de Stockage Distribué

La croissance du volume de données a rendu les architectures centralisées insuffisantes. Les systèmes distribués sont devenus la norme, mais posent un défi central : garantir un *lookup* efficace, la *consistency* et la *fault tolerance* dans un environnement de nœuds peu fiables.

Dans ce projet Master, nous comparons deux architectures de référence pour le stockage distribué, basées sur des paradigmes différents :

**1. L'architecture P2P structurée (Les DHTs)** Paradigme décentralisé (architecture *symmetric*) : les nœuds ont un rôle homogène et s'auto-organisent dans un *overlay* structuré. Nous considérons plusieurs DHT (Chord, CAN, Pastry, Kademlia) qui résolvent le *lookup* en général en  $O(\log N)$ , avec des compromis différents entre topologie logique, latence de routage, taille des tables d'état et résilience au *churn*.

**2. L'architecture hiérarchisée orientée colonnes (Modèle HBase)** À l'opposé du P2P pur, ce paradigme suit une architecture *master-worker* inspirée de Bigtable. HBase vise une cohérence forte, un modèle orienté colonnes/versionné, et conserve une centralisation partielle (HMaster) pour la gestion des métadonnées et des transactions, en échange de meilleures performances d'écriture et de scan. La suite du document présente d'abord le routage et la maintenance des DHTs, puis l'architecture interne de HBase et ses mécanismes de persistance.

## 1.1 Étude des approches P2P structurée: Les DHTs

Cette section résume les principes essentiels des *Distributed Hash Tables* (DHTs) : localisation des données, routage, gestion des nœuds et interfaces applicatives.

**Référence** : WEHRLE, GÖTZ et RIECHE (2005).

### 1.1.1 Introduction au problème du Lookup

Le problème central est le *lookup problem* : où stocker une donnée  $D$ , puis comment la retrouver dans un réseau distribué sans coordination centrale.

*"Où stocker, et comment trouver un certain élément de donnée  $D$  dans un système distribué sans aucun contrôle ou coordination centralisés ?"*




FIGURE 1 – **Le problème du lookup** : le nœud A stocke une donnée  $D$  et le nœud B doit la retrouver sans connaître son emplacement. [Source:schéma pris des notes de cours WEHRLE, GÖTZ et RIECHE 2005]

### 1.1.2 Comparaison des stratégies de recherche

Trois familles de solutions sont comparées.

#### 1. Central Server

Approche de **première génération** (ex. Napster). Un serveur central indexe les contenus. Recherche rapide en  $O(1)$ , mais dépendance forte à un *single point of failure*.




FIGURE 2 – **Central Server** : publication, requête au serveur central, puis téléchargement direct entre pairs. [Source:schéma pris des notes de cours WEHRLE, GÖTZ et RIECHE 2005]

#### 2. Flooding Search

Approche de **deuxième génération** (ex. Gnutella). La requête est propagée de voisin en voisin via un *reactive flooding* jusqu'au *Time To Live* (TTL). L'approche évite le serveur central, mais génère un fort *communication overhead* et des résultats non garantis.




FIGURE 3 – **Flooding Search** : diffusion récursive de requêtes, puis retour des nœuds ayant la donnée.  
[Source:schéma pris des notes de cours WEHRLE, GÖTZ et RIECHE 2005]

### 3. Distributed Hash Tables (DHTs)

Les DHTs (*structured Peer-to-Peer systems*) structurent l'*overlay* pour obtenir un compromis robuste :  $O(\log N)$  entrées de routage par nœud et  $O(\log N)$  hops pour localiser une donnée.




FIGURE 4 – **Distributed Hash Table** : routage structuré et efficace vers le nœud responsable.  
[Source:schéma pris des notes de cours WEHRLE, GÖTZ et RIECHE 2005]

Les Figures 2, 3, 4 et 5 montrent que les DHTs offrent le meilleur compromis entre coût de recherche et coût de stockage.




FIGURE 5 – Comparaison de la complexité en termes d'effort de recherche (axe y) et de coût de stockage par nœud (axe x). Les goulots d'étranglement (*bottlenecks*) ainsi que les caractéristiques spécifiques de chaque approche sont indiqués. [Source:schéma pris des notes de cours WEHRLE, GÖTZ et RIECHE 2005]

### 1.1.3 Fondamentaux des Distributed Hash Tables

Une DHT associe chaque clé à un nœud responsable via un espace d'adressage logique et un routage déterministe.

#### Gestion distribuée des données

Chaque nœud gère une plage de clés et conserve une *partial view* du système. Les messages sont relayés de nœud en nœud jusqu'à la destination.

#### Adressage dans les Distributed Hash Tables

Nœuds et données partagent le même *address space* logique (souvent très grand, p. ex. 0 à  $2^{160} - 1$ ). Les IDs sont produits par une *collision-resistant hash function*.




FIGURE 6 – Espace d'adressage linéaire partitionné entre paires. [Source:schéma pris des notes de cours WEHRLE, GÖTZ et RIECHE 2005]

#### Routage

Chaque nœud transmet vers un voisin plus proche de l'ID cible, ce qui réduit progressivement la distance jusqu'au nœud responsable en un *small number of hops*.




FIGURE 7 – Vue logique de la DHT et vue du réseau sous-jacent. [Source:schéma pris des notes de cours WEHRLE, GÖTZ et RIECHE 2005]

## Méthodes de stockage

**Direct Storage** : la donnée est copiée sur le nœud responsable (meilleure *availability*, coût plus élevé).

**Indirect Storage** : la DHT stocke un *pointer* vers la donnée (coût réduit, dépendance au nœud source).




FIGURE 8 – Comparaison entre stockage direct et stockage indirect. [Source:schéma pris des notes de cours WEHRLE, GÖTZ et RIECHE 2005]

### 1.1.4 Mécanismes des DHTs

La robustesse dépend de la gestion du *churn*, c'est-à-dire le taux de *joins* et *leaves* (arrivées/départs) ainsi que les pannes fréquentes.

#### Arrivée de nœuds

L'entrée d'un nœud suit quatre étapes courtes :

1. **Bootstrap** : le nouveau pair contacte un nœud existant qui sert d'*entry point*.
2. **Address Assignment** : il reçoit sa partition dans le *logical address space*.
3. **Routing Update** : les tables de routage sont ajustées pour intégrer le nouveau pair.
4. **Data Transfer** : les paires (*key, value*) devenues sa responsabilité lui sont transférées.

#### Défaillance de nœuds

Deux approches coexistent : *reactive recovery* (détection pendant le routage, puis route alternative) et *proactive recovery* (*probes* périodiques, remplacement préventif des entrées invalides). La *replication* limite la perte de données applicatives.

## Départ de nœuds

Un départ volontaire (*graceful leave*) facilite la migration immédiate des données vers le *successor* et accélère la convergence des tables de routage. Il améliore aussi la *routing efficiency* et stabilise les mécanismes de *replication* et de *load-balancing*.

### 1.1.5 Interfaces des DHTs




FIGURE 9 – Interface d’une Distributed Hash Table, typiquement put/get. [Source:schéma pris des notes de cours WEHRLE, GÖTZ et RIECHE 2005]

## Interface de routage

Interface *stateless* orientée messages : *send* livre vers un ID destination, *receive* remet les messages à l’application (*delivery semantics*). Cette *stateless interface* se concentre sur la livraison de paquets basés sur un ID logique plutôt que sur une adresse IP physique.

## Interface de stockage

Interface clé-valeur : *put* écrit la donnée, *get* la récupère. La couche gère *routing failures*, *replication* et *admission control*. Cette couche ajoute de la complexité car elle gère la persistance et la fiabilité des données, comme une table de *hash* distribuée.

## Interface Client

Des hôtes peuvent consommer le service DHT sans participer au routage de l’*overlay* (mode *client*). Ce mode est utile quand on veut séparer usage applicatif et participation au routage (fiabilité, politiques d’*access control*).

### 1.1.6 Conclusions

Les DHTs offrent une excellente *scalability* sans point central, mais imposent des compromis entre efficacité de routage, coût de maintenance et résilience au *churn*.

## Défis de conception

- **Routing Efficiency** : qualité du routage selon la structure des tables et la topologie.
- **Management Overhead** : coût de maintenance en continu.
- **Churn** : impact des arrivées/départs simultanés sur la stabilité.

## Limitations fondamentales

- **Untrusted Environments** : résistance difficile face aux nœuds malveillants et aux *Byzantine faults*.

- **Query Constraints** : *fuzzy searches* et requêtes textuelles complexes peu adaptées au modèle par identifiants.

## 1.2 Étude de l'approche hiérarchisée : HBase

Les DHT répondent bien au *lookup* (retrouver rapidement la machine qui détient une clé) dans des systèmes où les nœuds entrent et sortent fréquemment. En revanche, certaines charges exigent une cohérence plus stricte (lecture après écriture fiable), une meilleure persistance (données conservées malgré les pannes) et de bonnes performances de scan (lecture de plages de clés) en plus des écritures. L'approche hiérarchisée d'Apache HBase cible précisément ce compromis.

HBase, construit sur HDFS (*Hadoop Distributed File System*, couche de stockage distribué et répliqué), est une base NoSQL distribuée orientée grands volumes, c'est-à-dire une base non relationnelle conçue pour monter horizontalement sur plusieurs serveurs. Contrairement aux DHT décentralisées, HBase adopte un modèle *master-worker* : le Master coordonne le cluster et les workers (RegionServers) servent les données. Le *range partitioning* découpe les données en plages de clés triées ; chaque *row key* (identifiant de ligne) est donc routée de manière déterministe, ce qui favorise les scans séquentiels et une cohérence forte au niveau ligne.

### 1.2.1 Fondamentaux architecturaux de HBase

Avant de détailler les opérations PUT/GET, il est utile de situer les rôles des composants principaux. HBase s'appuie sur une architecture en couches : un **plan de contrôle** (HMaster et ZooKeeper) pour l'orchestration, un **plan de données** (RegionServers) pour les accès applicatifs, et une couche de persistance (WAL + HFiles sur HDFS) pour la durabilité.

Dans cette organisation, le client n'interagit pas en continu avec le Master pour chaque requête. Le Master sert surtout à localiser les régions et à gérer le cycle de vie du cluster (allocation, équilibrage, reprise sur panne), tandis que les échanges de lecture/écriture se font ensuite directement avec le RegionServer responsable de la plage de clés visée.

Avant de passer à l'analyse détaillée des performances, il est utile d'isoler le cycle d'une requête d'écriture puis de lecture pour comprendre où se situent le coût de localisation, le chemin de persistance et le point de service de la donnée.




FIGURE 10 – Diagramme simplifié des flux PUT/GET dans HBase. Pour un PUT (client A), le client commence par une résolution de métadonnées (HMaster/cache), envoie l'écriture au RegionServer ciblé (MemStore), puis la donnée est sécurisée via le Write-Ahead Log avant d'être persistée sous forme de HFiles sur HDFS (flush périodique). Pour un GET (client B), le client résout d'abord la localisation de la région, interroge le RegionServer cible, puis la valeur est servie depuis le BlockCache ou les HFiles selon la disponibilité des blocs. Cette vue fournit une lecture opérationnelle concise des chemins d'écriture et de lecture dans HBase.

Cette décomposition met en évidence un point important pour l'analyse comparative avec les DHT : la localisation est semi-indirecte (métadonnées puis accès direct), ce qui réduit le coût de routage après initialisation, mais introduit une dépendance à la qualité de la gestion des régions et du cache client.

Le *HBase Master* gère le cluster (allocation des régions, équilibrage, détection de pannes), tandis que les *RegionServers* stockent les données et exécutent les lectures/écritures. Cette séparation simplifie l'administration et le contrôle opérationnel.

## Modèle de données et espace d'adressage

Le modèle est orienté colonnes (tables, *rows*, familles de colonnes). Les *row keys* ordonnées lexico-graphiquement définissent l'espace d'adressage : excellent pour les scans et les requêtes par plages, mais sensible au design des clés.

### 1.2.2 Mécanismes internes : partitionnement et gestion des pannes

Deux mécanismes portent la scalabilité et la durabilité : partitionnement par régions et réaffectation après panne.

#### Partitionnement horizontal par plages de clés

Les tables sont découpées en régions couvrant des plages continues de *row keys*. Avec la croissance des données, *region splitting* répartit la charge entre *RegionServers*. Limite clé : des clés monotones (ex. timestamps) créent des *hotspots* et du *data skew* (*storage skew/access skew*).

Par rapport au *consistent hashing* des DHT (distribution pseudo-aléatoire), HBase choisit un partitionnement déterministe par ordre de clés.

#### Gestion des pannes et réaffectation

En cas de panne d'un *RegionServer*, le Master (avec ZooKeeper) réassigne les régions. Avec le *WAL* et HDFS, la reconstruction est robuste. Ce modèle est centralisé, contrairement à la réorganisation incrémentale des DHT.

### 1.2.3 Avantages et limites

**Avantages.** Cohérence forte par ligne, scans séquentiels performants et scalabilité horizontale via *region splitting* et ajout de *RegionServers*.

**Limites.** Le design des clés reste critique (risques de *hotspot* et de *data skew*), et l'exploitation est plus lourde qu'une DHT pure (HDFS, ZooKeeper, tuning et supervision).

## 1.3 Conclusion et justification du choix architectural

DHT et HBase répondent au même objectif (stockage distribué à grande échelle) avec des choix opposés : décentralisation + *consistent hashing* d'un côté, coordination centralisée + *range partitioning* de l'autre.

#### Critère d'évaluation : gestion du *data skew*

Le *data skew* est déterminant : HBase peut concentrer charge/stockage si les clés sont mal conçues, alors que les DHT réduisent structurellement ce risque via une distribution pseudo-aléatoire des identifiants.

## **Motivation du choix**

Notre objectif est d'implémenter un système totalement décentralisé en anneau logique. Les DHT sont mieux alignées avec cet objectif (routage distribué, auto-organisation, joins/leaves, absence de maître), tandis qu'une approche HBase déplacerait le projet vers l'ingénierie d'un cluster hiérarchisé.

## **Conclusion du choix**

HBase reste excellent pour des besoins de cohérence forte et de scans massifs, mais pour nos objectifs pédagogiques/expérimentaux, l'approche DHT est plus pertinente. En conséquence, nous retenons l'architecture DHT comme base de la suite du projet.

## **2 Première génération : architecture centralisée inspirée de Napster**

### 3 Deuxième génération : architecture non structurée inspirée de Gnutella

Cette deuxième implémentation ne repose pas encore sur une vraie DHT structurée au sens de *Chord* ou *Pastry*. Elle correspond plutôt à un réseau pair-à-pair non structuré, inspiré de *Gnutella 0.4*, dans lequel chaque nœud participe à la fois au stockage, au routage et aux échanges réseau. Cette approche a constitué une étape utile pour valider les mécanismes de communication, de découverte et de tolérance aux déconnexions avant l'introduction d'un anneau de hachage cohérent.

#### 3.1 Positionnement général et lien avec Gnutella

Le système suit un modèle *pure P2P* : il n'existe aucune séparation entre clients et serveurs. Chaque processus est un *servent* (*server* + *client*) capable de recevoir des connexions entrantes et d'initier lui-même des connexions sortantes.

| Aspect         | Implémentation réalisée    | Gnutella 0.4               |
|----------------|----------------------------|----------------------------|
| Topologie      | Maillage non structuré     | Maillage non structuré     |
| Routage        | Inondation limitée par TTL | Inondation limitée par TTL |
| Découverte     | PING/PONG                  | PING/PONG                  |
| Recherche      | GET                        | <i>Query</i>               |
| Réponse        | REPLY direct               | <i>QueryHit</i>            |
| Centralisation | Aucune                     | Aucune                     |

TABLE 1 – Résumé comparatif entre l'approche naïve développée et les principes de *Gnutella 0.4*.

Cette parenté avec *Gnutella* n'est pas seulement conceptuelle. Elle décrit bien l'intuition de départ : construire d'abord un système entièrement décentralisé, simple à expérimenter, puis observer empiriquement ses limites avant de passer à une DHT structurée.

#### 3.2 Problème initial : l'absence de vue globale

Le premier problème rencontré ne vient pas du transport réseau, mais du placement des données. Dans une topologie trop clairsemée, chaque pair ne connaît qu'un sous-ensemble des autres nœuds. Or si le choix du propriétaire d'une clé dépend de la vue locale du pair qui effectue le calcul, deux machines peuvent aboutir à des décisions différentes pour la même donnée.




FIGURE 11 – Problème de vue globale dans une topologie clairsemée. Le nœud 8001 stocke localement `user1` après avoir calculé  $\text{Hash}(\text{user1}) = 42$  avec sa propre vision du système. Plus tard, le nœud 8005 effectue un GET pour la même clé, mais avec une vue réseau différente il conclut que le propriétaire devrait être 8004 et relaie donc la requête dans une mauvaise direction. L'exemple montre qu'en l'absence d'un espace d'adressage partagé et stable, deux nœuds peuvent prendre des décisions incompatibles pour une même clé.

Ce constat a motivé un premier choix d'implémentation : tester explicitement une **structure en mesh** afin d'améliorer la cohérence de la vue réseau. Les schémas présentés dans cette section ne sont donc pas seulement illustratifs ; ils correspondent à des scénarios de test utilisés pour vérifier le comportement du système lorsque tous les nœuds se connaissent, puis lorsqu'un nœud disparaît.

On peut formaliser cette intuition simplement. Si l'on note  $V$  l'ensemble des nœuds actifs et  $E$  l'ensemble des liens de voisinage, alors un mesh complet correspond au graphe non orienté

$$G = (V, E), \quad E = \{\{u, v\} \mid u, v \in V, u \neq v\}.$$

Pour  $|V| = N$ , le nombre total d'arêtes vaut alors

$$|E| = \binom{N}{2} = \frac{N(N-1)}{2}.$$

Chaque nœud a donc un degré exactement égal à

$$\deg(v) = N - 1.$$

Cette propriété explique pourquoi la vue locale devient beaucoup plus cohérente : en régime stable, chaque pair voit directement tous les autres.

### 3.3 Passage à un mesh : ce que cela corrige, et ce que cela casse

Dans une topologie en maillage complet, chaque nœud possède a priori la même vue des participants actifs. Cette organisation réduit donc fortement le problème de vue globale : tant que le réseau reste stable, les pairs appliquent le même calcul de placement et convergent plus facilement vers le même propriétaire logique. Elle corrige aussi partiellement le problème du modulo naïf, car la cohérence de  $\mathbb{N}$  est meilleure tant que tous les pairs partagent la même vision du système.

En revanche, cette amélioration reste fragile. Dès qu'un nœud rejoint ou quitte le réseau, la valeur de  $N$  change et la fonction de placement  $\text{hash}(\text{key}) \% N$  peut désigner un autre propriétaire. Le maillage complet réduit donc l'incohérence à *l'instant donné*, mais ne supprime pas la dépendance structurelle au nombre de nœuds.

Cette fragilité se montre immédiatement par un petit raisonnement. Pour une clé de hachage  $h$ , le propriétaire logique dans le schéma naïf est

$$\text{owner}_N(h) = h \bmod N.$$

Après le départ d'un nœud, le système calcule au contraire

$$\text{owner}_{N-1}(h) = h \bmod (N - 1).$$

Les deux valeurs ne coïncident pas en général. Il suffit d'un contre-exemple pour le voir : avec  $h = 10$  et  $N = 4$ , on obtient

$$10 \bmod 4 = 2, \quad 10 \bmod 3 = 1.$$

Le propriétaire logique change donc alors même que la donnée n'a pas physiquement bougé. Plus généralement, l'ensemble des clés qui restent stables après le passage de  $N$  à  $N - 1$  est

$$S = \{h \in \mathbb{N} \mid h \bmod N = h \bmod (N - 1)\},$$

et cet ensemble est strictement plus petit que l'ensemble de toutes les clés ; il n'existe donc aucune garantie globale de stabilité sous churn.




FIGURE 12 – Impact du *churn* sur un placement basé sur  $\text{hash}(\text{key}) \% N$ . À gauche, avec quatre nœuds connectés en mesh, la clé `photo.jpg` est associée au nœud 8003, qui la stocke localement. À droite, après la panne du nœud 8004, la taille de la vue passe de 4 à 3 ; le même calcul désigne alors 8002 comme propriétaire logique. Le mesh améliore donc la cohérence de la vue tant que le système est stable, mais il ne protège pas contre l'instabilité du placement lorsque  $N$  varie.

Autrement dit, la structure en mesh règle en grande partie le problème de vue globale en régime stable, mais elle fait aussi apparaître plus clairement le vrai défaut du schéma naïf : la dépendance du placement au cardinal du réseau. Les tests de churn ont précisément servi à mettre ce point en évidence.

Du point de vue de la complexité, le mesh complet présente aussi un coût structurel élevé. Comme chaque nœud maintient  $N - 1$  voisins, la mémoire consacrée aux tables de voisinage est en  $\Theta(N)$  par pair, soit  $\Theta(N^2)$  à l'échelle du système. De même, un heartbeat envoyé à tous les voisins toutes les  $\Delta = 5$  secondes produit environ

$$N(N - 1)$$

messages de contrôle par période si l'on compte chaque émission directionnelle. Le coût de maintenance croît donc quadratiquement avec la taille du réseau.

Cette convergence vers un mesh plus dense n'a toutefois pas été obtenue d'emblée. Dans la pratique, il a fallu faire évoluer le mécanisme de découverte pour que les nœuds convergent rapidement vers une vue commune des participants actifs. Dans la version la plus simple, la vivacité du réseau reposait sur des messages PING/PONG et sur un *heartbeat* périodique : un nœud apprenait surtout l'existence de ses voisins immédiats, puis relayait éventuellement l'information de proche en proche. Ce fonctionnement suffisait pour maintenir un réseau connexe, mais la convergence restait lente et partielle si la topologie de départ était clairsemée.

Un mécanisme que l'on peut décrire comme du *pong caching* ou *peer exchange* a alors été introduit. Lorsqu'un nœud reçoit un PING, il ne répond plus seulement par un PONG attestant de sa propre présence. Il peut aussi renvoyer, dans la charge utile, l'adresse d'un petit nombre d'autres pairs déjà connus localement. Le pair initiateur enrichit alors son propre registre à partir de ces informations sans attendre une nouvelle inondation complète du réseau.




FIGURE 13 – Principe du *pong caching*. En plus d'annoncer sa propre présence, un nœud répondant à un PING peut transmettre quelques adresses supplémentaires issues de son registre local. Par diffusion répétée de ces informations, les pairs convergent plus vite vers une vue commune des participants actifs.

Dans notre contexte de simulation, ce mécanisme produit un effet important : une topologie initialement pauvre converge rapidement vers un maillage beaucoup plus dense, voire quasi complet à petite échelle. Cette convergence améliore à la fois la robustesse et la latence. D'une part, chaque nœud dispose de davantage de chemins alternatifs en cas de panne. D'autre part, le nombre de sauts nécessaires pour atteindre une grande partie des pairs diminue fortement, ce qui rend la diffusion des requêtes plus rapide et plus fiable.

### 3.4 Le flooding comme correction partielle

Une fois ce problème observé, la question n'était plus seulement "où stocker ?", mais aussi "comment retrouver une donnée quand le calcul local du propriétaire devient faux ou incomplet ?". C'est là que l'inondation limitée joue un rôle utile.

Dans cette version, lorsqu'un nœud reçoit une requête GET et qu'il ne possède pas localement la donnée recherchée, il la retransmet à l'ensemble de ses voisins connus. Le mécanisme est donc une

**inondation contrôlée.** Ce n'est pas une solution parfaite au problème de placement, mais c'est une **solution de rattrapage** : même si un nœud se trompe sur le propriétaire logique, la requête peut encore atteindre le bon détenteur effectif de la donnée à force de propagation dans le mesh.

- **Diffusion.** Une requête est rediffusée de pair en pair jusqu'à trouver un propriétaire potentiel.
- **TTL.** Un plafond `MAX_HOPS = 10` limite le nombre de sauts pour éviter les boucles infinies et contenir le trafic.
- **Élimination des doublons.** Le `PeerRegistry` mémorise les identifiants déjà vus, par exemple sous la forme `Type|Origin|Seq`, afin d'ignorer immédiatement les messages dupliqués.

On peut borner ce coût de recherche. Dans un graphe de degré moyen  $d$ , une inondation de profondeur maximale  $T$  génère, dans le pire cas sans élimination efficace des doublons, un nombre de transmissions majoré par une série géométrique :

$$1 + d + d^2 + \dots + d^T = \sum_{i=0}^T d^i.$$

Si  $d > 1$ , cette somme vaut

$$\sum_{i=0}^T d^i = \frac{d^{T+1} - 1}{d - 1},$$

soit un coût exponentiel en  $T$ . Dans un mesh complet, on peut prendre  $d = N - 1$ , ce qui donne une borne très pessimiste mais révélatrice : la redondance potentielle devient rapidement prohibitive quand  $N$  grandit.

Grâce au cache de messages déjà vus, l'implémentation réelle est heureusement plus proche d'un parcours borné des arêtes accessibles que d'une explosion purement exponentielle. Dans ce cas, une requête GET touche au plus chaque lien utile un nombre constant de fois, ce qui ramène l'ordre de grandeur à  $O(|E|)$ . Pour un mesh complet, cela reste

$$O(|E|) = O\left(\frac{N(N-1)}{2}\right) = O(N^2).$$

Même avec ce filtrage, le pire cas reste donc quadratique en nombre de nœuds. On peut l'écrire plus explicitement dans le cas d'un mesh complet. Comme  $|E| = \frac{N(N-1)}{2}$ , une recherche GET qui doit potentiellement explorer tout le réseau avant de conclure à un échec, ou avant d'atteindre le seul nœud possédant la donnée en dernier, effectue dans le pire cas un nombre de transmissions proportionnel à

$$T_{\text{worst}}(N) \approx 2|E| = N(N-1).$$

Le facteur 2 vient du fait qu'un lien bidirectionnel peut être sollicité dans les deux sens au cours de la propagation et des relais. On obtient donc

$$T_{\text{worst}}(N) \in \Theta(N^2).$$

Autrement dit, doubler le nombre de nœuds multiplie approximativement par quatre le coût maximal d'une recherche exhaustive, ce qui confirme que cette stratégie ne passe pas bien à l'échelle.

Ces bornes montrent bien l'ambivalence du flooding dans cette architecture naïve. D'un côté, il constitue un mécanisme de rattrapage robuste : si le réseau reste connexe, qu'aucun lien critique n'échoue pendant la recherche, et que le TTL est au moins égal au diamètre  $D$  du graphe, alors une requête émise depuis un nœud source finit nécessairement par atteindre tout nœud cible détenant la donnée. Dans un mesh complet, le diamètre vaut

$$D = 1,$$

ce qui explique pourquoi le flooding y est particulièrement efficace : tant que le système reste stable, la découverte est presque immédiate.

D'un autre côté, cette propriété se paie cher. Le flooding ne résout le problème que partiellement : il compense une mauvaise localisation par davantage de trafic réseau. Le système devient donc plus tolérant aux incohérences, mais au prix d'un coût en messages qui croît vite avec la taille du réseau. Cette tension entre *robustesse de découverte* et *coût quadratique ou pire* résume précisément la limite de l'approche naïve.




FIGURE 14 – Recherche par inondation dans l’approche naïve. Le nœud 8005 émet une requête GET `user1` ; celle-ci est relayée de proche en proche par les pairs intermédiaires, avec incrément du compteur de sauts, jusqu’au nœud 8001 qui possède la donnée dans son stockage local. Dans ce sens, le flooding corrige partiellement les erreurs de placement ou de vue locale : même si le demandeur ne connaît pas le bon propriétaire, la propagation augmente ses chances d’atteindre le nœud qui détient effectivement la donnée.

### 3.5 Réponse directe, puis *reverse path caching*

Une fois le mécanisme de flooding validé, la manière dont les réponses revenaient vers le demandeur a ensuite été modifiée. L’idée n’a pas été de transformer la recherche elle-même, mais plutôt de partir des limites de la réponse directe pour introduire une variante fondée sur la réutilisation du chemin de retour.

Dans la première version, lorsqu’un nœud trouvait la clé demandée après propagation d’une requête GET, il renvoyait la valeur directement au demandeur en ouvrant une connexion TCP dédiée grâce au champ `origin`. Ce choix était simple et plutôt efficace à petite échelle : la recherche restait diffuse, mais la réponse suivait un chemin direct.

Cette stratégie présentait toutefois une limite importante. Si une donnée devenait populaire, le nœud qui la détenait restait le seul à répondre à toutes les requêtes. La charge réseau et la charge de service se concentraient donc sur un unique point, tandis que les nœuds intermédiaires ne faisaient que relayer la recherche sans rien apprendre des données traversant le réseau. En pratique, le système restait fonctionnel, mais il ne tirait aucun bénéfice de la répétition des requêtes.

C’est précisément cette limite qui a conduit à l’introduction d’une deuxième version du mécanisme de réponse, fondée sur le *reverse path caching*. Au lieu de laisser le nœud propriétaire répondre directement au client par un nouveau canal, le chemin effectivement parcouru par la requête GET a été réutilisé.

Lors de la propagation de la requête, chaque nœud intermédiaire enregistre temporairement de quel voisin elle provient. Concrètement, une table de routage locale associe un identifiant de route, par exemple `seq:key`, à l’adresse du saut précédent. Ces entrées jouent le rôle de *breadcrumbs* : elles ne décrivent pas toute la topologie, mais elles suffisent à reconstruire un chemin de retour déterministe pour la réponse.

Lorsque le nœud propriétaire produit le message REPLY, celui-ci remonte alors exactement ce chemin inverse. À chaque saut, le nœud intermédiaire lit l’entrée correspondante, la supprime pour libérer la mémoire, met en cache localement la paire (`key`, `value`), puis transmet la réponse au saut précédent. La réponse ne suit donc plus un chemin direct indépendant ; elle exploite désormais la trace laissée par la requête initiale.

Cette modification change sensiblement le comportement du système, et la Figure 15 permet de le voir pas à pas. Lors du premier GET, le réseau est encore dans une situation de *cache miss* : le `lookup` rouge doit aller jusqu’au détenteur réel de la donnée, puis la réponse verte remonte tout le chemin inverse. C’est précisément pendant cette phase de retour que le cache se construit, puisque chaque nœud intermédiaire conserve une copie de la valeur avant de relayer le REPLY. Lors d’une requête ultérieure, on bascule alors vers un *cache hit* : le `lookup` peut être intercepté plus tôt, la réponse part depuis un nœud plus proche, et le chemin total devient plus court. Autrement dit, on passe d’une




FIGURE 15 – Lecture détaillée du *reverse path caching*. Dans la partie haute (*Lookup 1*), le chemin rouge correspond au *lookup* initial émis par le client connecté à 8005 pour obtenir *user1*. La donnée n'étant pas présente localement, il s'agit d'un *cache miss* : la requête progresse de pair en pair jusqu'au nœud 8001, qui possède la valeur dans son stockage local. Le chemin vert représente ensuite la réponse *REPLY* qui remonte en sens inverse ; à chaque saut, les nœuds intermédiaires utilisent les *breadcrumbs* laissés par le *lookup* pour relayer la réponse et mettre immédiatement la donnée en cache. Dans la partie basse (*Lookup 2*), une nouvelle requête pour la même clé repart de 8005, mais elle rencontre cette fois un *cache hit* sur un nœud intermédiaire proche, ici 8004. Le *lookup* rouge est alors plus court, et la réponse verte revient directement sans devoir remonter jusqu'au propriétaire initial 8001. Le schéma montre ainsi à la fois le premier *cache miss*, la phase d'amorçage du cache le long du chemin inverse, puis le second *cache hit* qui réduit la distance de résolution.

logique où chaque demande repart presque de zéro à une logique d'apprentissage progressif du réseau. La recherche reste fondée sur le flooding, mais son coût effectif peut diminuer fortement pour les données populaires grâce à cette mise en cache opportuniste.

### 3.6 Usages réels et intérêt pratique

Il serait toutefois réducteur de conclure que ce type d'architecture n'a aucun intérêt pratique. Sous sa forme brute, un réseau entièrement de type Gnutella passe mal à l'échelle pour un stockage distribué global, précisément à cause du coût du flooding et de l'instabilité du placement. En revanche, ses idées restent très utiles dans des contextes où la simplicité, la robustesse et la découverte rapide priment sur l'optimalité asymptotique.

On retrouve aujourd'hui ces idées dans des briques très concrètes.

Sur un réseau local, **mDNS** (*multicast DNS*) est un mécanisme de découverte sans infrastructure (<https://datatracker.ietf.org/doc/html/rfc6762>). Son rôle est simple : permettre à des machines présentes sur le même réseau de s'annoncer mutuellement et de découvrir rapidement leurs voisins sans passer par un serveur central. L'idée est très proche de notre approche naïve : on privilégie la simplicité, la visibilité rapide et l'absence de coordination centrale.

Dans l'écosystème **libp2p**, on retrouve également cette logique pour la découverte locale des pairs (<https://libp2p.io/docs/mdns/>). Un nœud peut ainsi détecter d'autres participants proches et établir rapidement ses premières connexions. À un autre niveau, les protocoles *Floodsub* puis surtout *Gossipsub* servent à diffuser des messages dans le réseau pair-à-pair (<https://libp2p.io/docs/pubsub/>). Ils reprennent l'intuition du flooding, mais sous une forme mieux contrôlée afin de limiter le trafic inutile.

Dans les **blockchains modernes**, la couche réseau pair-à-pair conserve elle aussi cette idée de propagation rapide (<https://ethereum.org/developers/docs/networking-layer/>). Concrètement, les nœuds commencent par découvrir d'autres pairs, puis utilisent un mécanisme de type gossip pour transmettre transactions et blocs à travers le réseau. L'objectif n'est pas de stocker les données via

une DHT naïve, mais de propager vite et sans point central une information qui doit atteindre un grand nombre de participants.

Autrement dit, l'approche naïve inspirée de Gnutella reste pertinente comme brique de base pour des tâches bien ciblées : trouver rapidement des voisins, diffuser une information à grande vitesse, ou maintenir une connectivité décentralisée sans coordinateur central. Ce ne sont pas les mêmes objectifs qu'une DHT structurée ; c'est précisément pourquoi, dans les systèmes réels, ces mécanismes coexistent souvent avec des structures plus élaborées au lieu de les remplacer entièrement.

### 3.7 Bilan

Cette deuxième génération a permis de valider plusieurs briques essentielles : communication TCP fiable, sérialisation des messages, gestion des connexions concurrentes, découverte des pairs, surveillance de la vivacité et recherche distribuée. Elle a surtout montré une progression expérimentale claire : d'abord, le mécanisme de découverte a permis au réseau de converger vers un mesh beaucoup plus cohérent ; ensuite, le *reverse path caching* a permis de réutiliser les chemins de retour pour diffuser des copies utiles des données.

Du point de vue des performances, cette architecture a toutefois un comportement très contrasté. Dans le meilleur cas, si la donnée est locale ou si le bon pair est immédiatement accessible, une requête GET se résout en pratique en  $O(1)$  sauts. Dans le pire cas, au contraire, la recherche doit explorer une grande partie du réseau ; sur un mesh complet, son coût atteint alors  $\Theta(N^2)$  en nombre de transmissions. De la même manière, la topologie complète offre un diamètre minimal égal à 1, ce qui maximise la rapidité de découverte, mais son coût structurel reste quadratique : chaque pair maintient  $N - 1$  voisins, soit une mémoire en  $\Theta(N)$  localement et en  $\Theta(N^2)$  à l'échelle du système.

Le rôle de la topologie est donc central. Une topologie clairsemée réduit les coûts de maintenance, mais elle produit des vues locales divergentes et donc des décisions incompatibles sur le placement des clés. À l'inverse, un mesh complet améliore fortement la cohérence de la vue réseau, mais il ne corrige pas le problème fondamental du placement par  $\text{hash}(\text{key}) \% N$  : dès que  $N$  varie, le propriétaire logique d'une clé peut changer. On obtient donc un compromis défavorable entre cohérence locale, coût de maintenance et stabilité globale du placement.

En revanche, pour le placement stable des données et le routage scalable, ces améliorations restent palliatives. Le mesh ne supprime pas la dépendance à  $N$ , et le flooding compense l'erreur par un surcoût en messages. Ces limites motivent directement l'introduction de vraies DHT structurées dans la suite du rapport. Des approches comme *Chord* ou *Pastry* remplacent la dépendance à  $N$  par un espace d'identifiants fixe et introduisent des mécanismes de routage déterministes, beaucoup mieux adaptés à un environnement distribué dynamique.

## 4 Troisième génération : DHT structurée inspirée de Chord

Cette troisième génération correspond au passage vers une DHT réellement structurée. L'idée n'est plus de compenser les limites d'un réseau non structuré par du flooding ou par une connaissance partielle des pairs, mais de reposer sur un espace d'identifiants commun et sur un routage déterministe. Plusieurs protocoles illustrent cette famille de DHT structurées. *Chord* organise les nœuds sur un anneau logique et utilise des sauts logarithmiques à l'aide d'une *finger table* pour retrouver le responsable d'une clé. *Pastry* repose sur un routage par préfixes : à chaque étape, le message progresse vers un nœud dont l'identifiant partage un préfixe plus long avec la clé recherchée. *Kademlia*, de son côté, structure la recherche autour d'une distance XOR entre identifiants et choisit à chaque saut des nœuds de plus en plus proches de la cible selon cette métrique. D'autres approches comme *CAN* répartissent enfin l'espace des clés dans un espace cartésien virtuel où le routage se fait de zone en zone entre voisins.

Dans la suite du rapport, nous nous concentrons toutefois sur *Chord*, qui sert de base à l'implémentation présentée. Les autres protocoles sont évoqués ici comme points de comparaison pour situer notre travail parmi les principales DHT structurées.

### 4.1 Chord

Chord est un protocole DHT (*Distributed Hash Table*) qui résout un problème unique : trouver rapidement le nœud responsable d'une clé dans un réseau pair-à-pair dynamique.

#### 4.1.1 Principe de fonctionnement

Chaque nœud et chaque clé reçoivent un identifiant sur  $m$  bits (souvent via SHA-1), placé sur un anneau modulo  $2^m$ . Une clé  $k$  est stockée sur son *successor* : le premier nœud rencontré dans le sens horaire dont l'identifiant est supérieur ou à  $k$ .

Cette règle donne trois propriétés utiles :

- **Répartition** : le *consistent hashing* distribue les clés de manière quasi uniforme.
- **Scalabilité** : l'ajout/retrait d'un nœud ne déplace qu'une fraction des clés.
- **Décentralisation** : aucun serveur central n'est requis.

#### 4.1.2 Routage efficace : Finger Table

Pour éviter un parcours linéaire de l'anneau, chaque nœud maintient une **finger table** de  $m$  entrées. L'entrée  $i$  pointe vers le premier nœud joignable à partir de  $n + 2^{i-1}$ .

$$\text{finger}[i].\text{start} = (n + 2^{i-1}) \bmod 2^m$$

Cette structure permet des sauts exponentiels et un coût moyen de recherche en  $O(\log N)$  messages.

#### 4.1.3 Algorithmes essentiels

##### 1) Recherche de la clé : `find_successor(id)`

- Si `id` est entre le nœud courant et son *successor*, on retourne ce *successor*.
- Sinon, on avance vers le *closest\_preceding\_node(id)* dans la finger table et on répète.

##### 2) Choix du prochain saut : `closest_preceding_node(id)`

- Parcours de la finger table du plus grand saut au plus petit.
- Retour du premier doigt situé strictement avant `id` sur l'anneau.

##### 3) Arrivée d'un nœud : `join(n')`

- Le nouveau nœud contacte un nœud connu  $n'$ .
- Il initialise son *successor* via `find_successor` puis construit sa finger table.

**4) Stabilisation :** `stabilize()` et `notify()`

- Exécution périodique pour corriger les pointeurs *successor/predecessor*.
- Garantit la convergence vers un anneau cohérent après churn modéré.

**5) Tolérance aux pannes :** `successor list`

- Chaque nœud conserve plusieurs successeurs de secours.
- En cas de panne du successeur principal, le routage continue via le suivant vivant.

**4.1.4 Complexité (résumé)**

- **Lookup** :  $O(\log N)$  messages.
- **Maintenance d'un join/leave** : surcoût logarithmique (dépend de la politique de mise à jour).
- **Mémoire par nœud** :  $O(\log N)$  entrées de routage.

En pratique, Chord fournit une base simple et robuste pour le *lookup* distribué : routage logarithmique, maintenance locale périodique et bonne résilience aux variations du réseau.

**4.2 Implémentation de Chord**