

Système de stockage distribué basé sur une DHT

Projet Master Systèmes et Applications Répartis (SAR)

PSAR – Sorbonne Université

Auteurs: Cedric Genevieve, Safa Gunes, Somaya Boudalil
Étudiants en Master 2026 — Systèmes et Applications Répartis

Instructeur: Prof. Alessio Pagliari

Date: 17 février 2026

Table des matières

1	Analyse Comparative des Paradigmes Architecturaux de Stockage Distribué	3
1.1	Étude des approches P2P structurée: Les DHTs	3
1.1.1	Introduction au problème du Lookup (ref. Section 7.1)	4
1.1.2	Comparaison des stratégies de recherche (ref. Section 7.1.1 - 7.1.5)	5
1.1.3	Fondamentaux des Distributed Hash Tables (ref. Section 7.2)	7
1.1.4	Mécanismes des DHTs (ref. Section 7.3)	9
1.1.5	Interfaces des DHTs (ref. Section 7.4)	10
1.1.6	Conclusions (ref. Section 7.5)	11
1.2	Étude de l'approche hiérarchisée : HBase	12
1.2.1	Introduction au modèle hiérarchisé	12
1.2.2	Fondamentaux architecturaux de HBase	12
1.2.3	Mécanismes internes : partitionnement et gestion des pannes	13
1.2.4	Avantages et limites	13
1.3	Conclusion et justification du choix architectural	14
2	Méthode de répartition des données	15
2.1	Motivation et définition de la répartition des données	15
2.2	Les différentes méthodes de répartitions des données	17
2.2.1	hachage classique	17
2.2.2	Hachage cohérent (Consistent Hashing)	19
2.3	Conclusion sur les méthodes de répartitions des données	23
3	Chord	23
3.1	Design du système et philosophie	23
3.2	Consistent Hashing et l'Identifiant Circle	24
3.3	Localisation de clés scalable : Finger Tables	24
3.4	Théorèmes	25
3.5	Algorithmes des nœuds	26
3.6	Algorithmes de la Finger Table	28
4	Pastry	29
4.1	Architecture générale	29
4.2	Identifiants et espace de clés	30
4.3	Structures de routage	30
4.3.1	1. Routing Table	30
4.3.2	2. Leaf Set (ensemble des feuilles)	30
4.3.3	3. Neighbor Set (ensemble des voisins)	30
4.4	Processus de routage	30
4.5	Algorithmes des nœuds et maintenance	31
5	Architecture du système et cycle de vie d'une requête	31
5.1	Choix architecturaux et problématique	31
5.1.1	Architecture générale basée sur Chord	31

5.1.2	Couche Overlay et Couche applicative	32
5.1.3	Cycle de vie d'une requête	32
5.1.4	Conclusion sur l'architecture Chord	33

1 Analyse Comparative des Paradigmes Architecturaux de Stockage Distribué

L'explosion exponentielle du volume de données généré par les applications modernes a rendu obsoletes les architectures de stockage centralisées traditionnelles. Face à la nécessité de gérer des pétaoctets de données avec une haute disponibilité, les systèmes distribués se sont imposés comme la solution standard. Cependant, la distribution des données sur un grand nombre de nœuds introduit une complexité majeure : comment garantir la localisation efficace de la donnée (*lookup*), la cohérence (*consistency*) et la tolérance aux pannes (*fault tolerance*) dans un environnement où les machines sont intrinsèquement peu fiables ?

Dans le cadre de ce projet Master, nous nous intéressons à deux architectures de référence qui répondent à ces problématiques selon des paradigmes radicalement différents. Cette introduction analyse et compare ces deux modèles architecturaux considérés pour notre système de stockage :

1. L'architecture P2P structurée (Les DHTs) Ce premier paradigme repose sur une décentralisation totale (architecture *symmetric*). Chaque nœud joue un rôle identique, et le système s'auto-organise pour former un *overlay* structuré.

Plutôt que de nous limiter à une solution unique, nous étudierons plusieurs algorithmes de DHT (tels que Chord, mais aussi d'autres approches comme CAN, Pastry ou Kademlia). Bien que tous ces protocoles visent à résoudre le problème du *lookup* de manière scalable (généralement en $O(\log N)$ ou mieux), ils diffèrent par leurs topologies logiques (anneau, hypercube, arbre) et leurs stratégies de maintenance face au *churn*. Cette diversité permet d'analyser les compromis entre la latence de routage, la taille des tables d'état et la résilience du réseau.

2. L'architecture hiérarchisée orientée colonnes (Modèle HBase) À l'opposé de l'approche P2P pure, ce second paradigme adopte une architecture *master-worker* plus structurée, inspirée du Bigtable de Google. Ici, le système est conçu pour offrir une cohérence forte et un modèle de données riche (orienté colonnes, versionné). Bien que distribué, ce modèle conserve des éléments de centralisation (via le HMaster) pour simplifier la gestion des métadonnées et des transactions. HBase illustre comment sacrifier une part de l'autonomie des nœuds permet d'optimiser les performances d'écriture et de scan sur de très larges ensembles de données.

La suite de ce document synthétise d'abord les mécanismes de routage et de maintenance des DHTs, avant d'aborder l'architecture interne de HBase et ses mécanismes de persistance.

1.1 Étude des approches P2P structurée: Les DHTs

Cette section s'appuie sur l'intégralité des notes de cours référencées afin de fournir une vue d'ensemble exhaustive du sujet. Ces notes sont considérées comme particulièrement complètes dans la mesure où elles couvrent l'ensemble du spectre technologique : de l'historique des systèmes distribués à l'adressage de bas niveau et au "*content-based routing*", jusqu'aux interfaces applicatives de haut niveau. Ce document offre une feuille de route permettant de comprendre comment les systèmes massivement distribués maintiennent leur stabilité sous une "*heavy network load*".

Référence : DBLP:conf/p2p/WehrleGR05.

1.1.1 Introduction au problème du Lookup (ref. Section 7.1)

Le document débute en notant une transition des systèmes distribués vers des réseaux massifs comptant des millions de participants, tels que Skype et BitTorrent. Ces systèmes doivent gérer la *"scalability, flexibility, and instant deployment"* sans aucun contrôle centralisé.

Au cœur de ces réseaux réside le **lookup problem**. Il est intéressant de noter que le document réduit cette problématique à une question unique :

"Où stocker, et comment trouver un certain élément de donnée D dans un système distribué sans aucun contrôle ou coordination centralisés ?"

L'objectif est qu'un nœud puisse récupérer un élément de donnée D spécifique sans avoir de connaissance préalable de l'emplacement actuel de D.




FIGURE 1 – **Le problème du lookup** : le nœud A souhaite stocker un élément de donnée D dans le système distribué. Le nœud B souhaite récupérer D sans connaissance préalable de l'emplacement actuel de D. Comment le système distribué — notamment le placement et la récupération des données — doit-il être organisé (en particulier au regard de la *scalability* et de l'efficacité) ?

1.1.2 Comparaison des stratégies de recherche (ref. Section 7.1.1 - 7.1.5)

Pour justifier l'usage des DHTs, le texte compare trois méthodes principales de gestion et de récupération des données :

1. Central Server

Cette approche de "première génération" (ex: Napster) implique un serveur central qui garde trace de l'emplacement de chaque élément.

En termes de performance, elle est très rapide, avec une complexité de recherche de $O(1)$. De plus, elle permet des *"fuzzy and complex queries"* car le serveur possède une vue globale.

Cependant, elle représente un *"single point of failure"*. Si le serveur échoue ou est attaqué, l'ensemble du système devient inutilisable.




FIGURE 2 – **Central Server** : (1) Le nœud A publie son contenu sur le serveur central S. (2) Un nœud B interroge le serveur central S pour obtenir la localisation réelle d'un élément de donnée D. (3) Si celui-ci existe, S répond en indiquant la localisation de D. (4) Le nœud demandeur B télécharge le contenu directement depuis le nœud A.

2. Flooding Search

Utilisée par les systèmes de "deuxième génération" comme Gnutella, cette méthode supprime totalement le serveur.

Le mécanisme consiste en l'envoi par un nœud d'une requête à ses voisins, qui la propagent par *"flood"* aux nœuds suivants jusqu'à ce qu'un *"Time to Live"* (TTL) soit atteint.

Sa scalabilité est médiocre car l'*"communication overhead"* est extrêmement élevé. De plus, les résultats de recherche ne sont pas garantis car la recherche ne couvre qu'un nombre limité de *hops*, n'offrant donc pas la fiabilité requise pour ces applications.




FIGURE 3 – **Flooding Search** : Aucune information de routage n'est maintenue dans les nœuds intermédiaires. (1) Le nœud A envoie une requête pour l'élément D à ses "neighbours" au sein du système distribué. Ces derniers transmettent la requête aux nœuds suivants de manière récursive (*flooding / breadth-first search*). (2) Le ou les nœuds stockant D envoient une réponse à A, puis A télécharge D directement depuis le ou les nœuds ayant répondu.

3. Distributed Hash Tables (DHTs)

Le document décrit les DHTs comme la "*golden path*" évitant les inconvénients des deux autres méthodes.

Elles sont souvent appelées "*structured Peer-to-Peer systems*" car elles utilisent des procédures proactives pour organiser le réseau. Chaque nœud ne gère qu'un petit nombre de références ($O(\log N)$), et les données peuvent être localisées en $O(\log N)$ hops.




FIGURE 4 – **Distributed Hash Table** : Les nœuds du système distribué s'organisent en un *structured overlay* et établissent une quantité restreinte d'informations de routage afin d'assurer un routage rapide et efficace vers les autres nœuds de l'*overlay*. (1) Le nœud A envoie une requête pour l'élément D à un nœud arbitraire de la DHT. (2) La requête est transmise selon le routage de la DHT en $O(\log N)$ hops vers le nœud cible. (3) Le nœud cible envoie D au nœud A.

Réf : La Table 7.1 et la Figure 7.4 fournissent une comparaison directe de ces complexités, soulignant que les DHTs offrent le meilleur équilibre entre efficacité et robustesse.




FIGURE 5 – Comparaison de la complexité en termes d'effort de recherche (axe y) et de coût de stockage par nœud (axe x). Les goulots d'étranglement (*bottlenecks*) ainsi que les caractéristiques spécifiques de chaque approche sont indiqués.

1.1.3 Fondamentaux des Distributed Hash Tables (ref. Section 7.2)

Cette section explore la stratégie proactive utilisée par les DHTs pour gérer les données, garantissant que chaque nœud possède un rôle spécifique et prévisible dans le réseau. Les DHTs gèrent les données en les distribuant entre les nœuds et en utilisant un "*deterministic routing scheme*".

Gestion distribuée des données (ref. Section 7.2.1)

Contrairement aux systèmes non structurés qui reposent sur un "*reactive flooding*" pour trouver des éléments, une DHT est "proactive".

Chaque nœud se voit assigner une "*range of data items*" spécifique dont il est responsable. Chaque nœud maintient une "*partial view*" de l'ensemble du système, stockant un nombre limité de liens vers d'autres nœuds.

Le processus de routage traverse plusieurs nœuds, se rapprochant de la destination à chaque *hop* jusqu'à ce que la cible soit atteinte.

Adressage dans les Distributed Hash Tables (ref. Section 7.2.2)

Les DHTs fonctionnent en créant un "*address space*" virtuel qui existe indépendamment de la topologie physique du réseau.

Ces espaces consistent généralement en de très grands entiers (par exemple de 0 à $2^{160} - 1$). Chaque nœud participant se voit attribuer une "*contiguous portion*" de cet espace d'adressage.

Les éléments de données reçoivent un "*identifiant ID*" unique dans le même espace, généralement en utilisant une "*collision-resistant hash function*" comme SHA-1 sur le nom du fichier ou son contenu.

Comme illustré dans la Figure 7.6, l'espace d'adressage est souvent interprété géométriquement comme un cercle ou un anneau.

Routage (ref. Section 7.2.3)

Le routage est la fonctionnalité centrale qui résout le *lookup problem*. Les nœuds ne connaissent pas tous les autres nœuds ; ils ne stockent qu'un "*bounded number of links*".




FIGURE 6 – Un espace d'adressage linéaire avec des valeurs entières allant de 0 à 65,535. L'espace d'adressage est partitionné entre huit paires.




FIGURE 7 – Vue d'ensemble et vue du réseau sous-jacent (*underlay*) d'une Distributed Hash Table.

Si un nœud reçoit un message pour un ID qu'il ne possède pas, il le transmet au nœud de sa table qui est numériquement le plus proche de l'ID cible. Ce processus récursif est conçu pour trouver efficacement la destination en un "*small number of hops*".

*

Méthodes de stockage (ref. Section 7.2.4)

Il existe deux manières principales de stocker les données une fois le nœud responsable localisé, comme illustré dans la Figure 7.8 :




FIGURE 8 – Comparaison des deux méthodes de stockage des données au sein des Distributed Hash Tables : le *Direct Storage* et l'*Indirect Storage*.

Direct Storage : La donnée réelle est copiée sur le nœud responsable. C'est excellent pour la *availability* mais consomme plus de bande passante et de stockage.

Indirect Storage : Le nœud ne stocke qu'un "*pointer*" ou une référence vers l'endroit où la donnée est réellement conservée. Cela réduit la charge, mais signifie que la donnée est perdue si le nœud d'origine se déconnecte.

1.1.4 Mécanismes des DHTs (ref. Section 7.3)

Cette section se concentre sur la gestion des données et des nœuds, spécifiquement sur la manière dont le système gère l'arrivée, le départ et l'occurrence fréquente de *node failure*.

Avant qu'un nœud puisse interagir avec les données, il doit rejoindre le réseau. Cette arrivée déclenche des changements dans l'infrastructure, nécessitant la mise à jour des informations de routage et de la distribution des données. À l'inverse, le système doit détecter et s'adapter chaque fois qu'un nœud quitte le réseau ou échoue.

Arrivée de nœuds (ref. Section 7.3.2)

Le document spécifie un processus en quatre étapes pour qu'un nouveau nœud rejoigne la DHT :

1. **Bootstrap** : Le nouveau nœud utilise une méthode de *bootstrap* pour contacter un nœud existant arbitraire, qui sert d'*"entry point"*.
2. **Address Assignment** : Le nœud reçoit sa propre *"partition in the logical address space"*.
3. **Routing Update** : Les autres nœuds du système mettent à jour leurs informations de routage pour reconnaître le nouveau membre.
4. **Data Transfer** : Le nouveau nœud récupère les paires (*key, value*) dont il est désormais responsable auprès du nœud qui les détenait précédemment.

Défaillance de nœuds (ref. Section 7.3.3)

Parce que les systèmes distribués consistent souvent en des machines de bureau peu fiables et mal connectées, les défaillances sont fréquentes. Les DHTs gèrent cela via deux types de récupération :

Reactive Recovery : Si un nœud rencontre un pair défaillant lors d'une opération régulière, il gère la faute en trouvant des routes alternatives.

Proactive Recovery : Le système sonde périodiquement les autres nœuds (*"probes"*) pour vérifier leur statut. Si un nœud est non opérationnel, son entrée de routage est remplacée.

En cas d'échec d'un nœud, les données applicatives qu'il stockait sont perdues, à moins que la *"replication"* ne soit utilisée. Certains systèmes utilisent une approche *"soft-state"* où les données sont supprimées (*"pruned"*) à moins que l'application ne les rafraîchisse périodiquement.

Départ de nœuds (ref. Section 7.3.4)

Bien que les nœuds puissent être traités comme des *"failed nodes"* s'ils disparaissent, les DHTs préfèrent que les nœuds notifient le système avant de partir. Ce départ volontaire permet au système de copier immédiatement les données du nœud sortant vers son *successor*, de mettre à jour le routage plus rapidement (améliorant l'*"routing efficiency"*) et de garantir le bon fonctionnement des mécanismes de *"replication and load-balancing"*.

1.1.5 Interfaces des DHTs (ref. Section 7.4)




FIGURE 9 – Interface d’une Distributed Hash Table. À travers une simple interface put/get, la DHT fait abstraction de la distribution des données entre les nœuds.

Les notes de cours mentionnent deux angles principaux pour considérer la fonctionnalité d’une DHT : comme un système de routage ou comme un système de stockage.

Interface de routage (ref. Section 7.4.1)

Cette “*stateless interface*” se concentre sur la livraison de paquets basés sur un ID de destination plutôt que sur une adresse IP physique.

La primitive *send* accepte un ID de destination et un message, le livrant au nœud responsable depuis n’importe quel point du réseau. La primitive *receive* transmet les messages entrants et leurs identifiants à l’application sur le nœud récepteur. Cette interface étant générique, les développeurs peuvent implémenter leurs propres stratégies de stockage et de *load-balancing*.

Interface de stockage (ref. Section 7.4.2)

Cette couche ajoute de la complexité en gérant la persistance et la fiabilité des données. Comme le montre la Figure 7.9, elle imite une table de *hash* standard.

put prend une paire (*key*, *value*) et la stocke sur le nœud responsable. *get* accepte un identifiant et renvoie la valeur associée. La couche de stockage doit gérer les “*routing failures*”, prévenir la perte de données via la “*replication*” et gérer l’“*admission control*”.

Interface Client (ref. Section 7.4.3)

Le document note également que des nœuds peuvent agir comme de simples “*clients*”. Cela permet à des hôtes non-participants d’utiliser les services de la DHT sans rejoindre le réseau *overlay*, ce qui est utile pour la fiabilité ou l’“*access control*”.

1.1.6 Conclusions (ref. Section 7.5)

Le texte conclut en pesant les avantages significatifs des DHTs face à leurs défis persistants. Bien qu'elles résolvent les problèmes de *scalability* des systèmes centralisés, elles ne constituent pas une solution universelle.

Défis de conception

Les développeurs doivent naviguer entre plusieurs objectifs conflictuels :

- **Routing Efficiency** : Influencée par le nombre de références aux autres nœuds et la connaissance de la topologie au niveau IP.
- **Management Overhead** : Le coût de fond pour maintenir la DHT même en l'absence de trafic actif.
- **Churn** : Les taux élevés de *joins* et *leaves* simultanés exercent un stress particulier sur la stabilité globale, pouvant mener à des systèmes défectueux.

Limitations fondamentales

Malgré leur efficacité, les DHTs font face à des défis liés au principe de l'indexation distribuée :

- **Untrusted Environments** : Difficulté d'opérer de manière fiable lorsque les nœuds sont malveillants (*Byzantine faults*).
- **Query Constraints** : La récupération étant basée sur des identifiants numériques, effectuer des "*fuzzy searches*" ou des requêtes textuelles complexes est extrêmement difficile à réaliser efficacement.

1.2 Étude de l'approche hiérarchisée : HBase

Alors que la section précédente a mis en évidence la problématique fondamentale du stockage distribué — à savoir où stocker une donnée et comment la retrouver dans un système sans coordination centralisée — les DHT apportent une réponse fondée sur le hachage cohérent et l'auto-organisation pair-à-pair.

Cependant, si des systèmes comme Chord permettent une localisation efficace dans des environnements dynamiques, certaines applications nécessitent des garanties supplémentaires comme un modèle de données plus structuré, une persistance forte, un contrôle plus fin de la cohérence, et une meilleure maîtrise des performances en lecture et écriture.

C'est dans ce contexte que s'inscrit l'approche hiérarchisée incarnée par HBase.

1.2.1 Introduction au modèle hiérarchisé

Développé au sein de l'écosystème Apache Hadoop, HBase est une base de données NoSQL distribuée construite au-dessus de HDFS (*Hadoop Distributed File System*). Elle est conçue pour stocker et gérer de très grands volumes de données structurées ou semi-structurées, tout en fournissant un accès rapide et aléatoire en lecture et en écriture.

Contrairement aux DHT, dont l'architecture repose sur une organisation entièrement décentralisée et un routage basé sur le hachage, HBase adopte une structure hiérarchisée de type maître-esclave. Le partitionnement des données n'est pas réalisé via un hachage aléatoire, mais par plages ordonnées de clés (range partitioning). Ce choix architectural permet une localisation déterministe des données, une meilleure prise en charge des scans séquentiels, et une cohérence forte au niveau des lignes.

1.2.2 Fondamentaux architecturaux de HBase

HBase repose sur une architecture de type maître-esclave. Le système est composé d'un HBase Master et de plusieurs RegionServers.

Le HBase Master est responsable de la gestion globale du cluster : attribution et répartition des régions, détection des pannes, équilibrage de charge et gestion des opérations de création ou suppression de tables.

Les RegionServers, quant à eux, assurent le stockage effectif des données et traitent les requêtes de lecture et d'écriture des clients.

Ainsi, HBase distingue explicitement les responsabilités, ce qui permet une gestion centralisée du partitionnement et une meilleure maîtrise opérationnelle.

Modèle de données et espace d'adressage

Le modèle de données de HBase est orienté colonnes et s'inspire de l'approche BigTable. Les données sont organisées en Tables, Lignes (rows) identifiées par une row key unique et Familles de colonnes.

L'espace d'adressage est basé sur des lignes ordonnées lexicographiquement selon leur clé. Cette organisation impose un adressage déterministe : la position d'une donnée dépend directement de sa clé et de son ordre relatif.

Ce choix architectural favorise les opérations de scan séquentiel et les requêtes par plages de clés, mais nécessite une gestion attentive de la conception des clés afin d'éviter les déséquilibres de charge.

1.2.3 Mécanismes internes : partitionnement et gestion des pannes

Cette section analyse les mécanismes internes, en particulier le partitionnement et la gestion des pannes, qui permettent à Apache HBase d'assurer la scalabilité et la durabilité des données dans un environnement distribué.

Partitionnement horizontal par plages de clés

L'une des caractéristiques centrales de HBase est le partitionnement horizontal des données.

Une table est découpée en régions, chacune couvrant une plage continue de clés (row keys). Chaque région contient donc un sous-ensemble ordonné des lignes de la table. Ce découpage permet de répartir les données entre plusieurs RegionServers et d'assurer la scalabilité horizontale du système.

À mesure que le volume de données augmente, une région peut automatiquement se scinder en deux régions plus petites (region splitting). Ce mécanisme dynamique permet d'équilibrer la charge entre les serveurs et d'éviter qu'une région ne devienne trop volumineuse pour maintenir des performances stables.

Toutefois, l'efficacité de cette distribution dépend fortement du choix des clés. Si les clés suivent une progression monotone (par exemple des timestamps croissants), un phénomène de hotspot peut apparaître : toutes les nouvelles écritures sont dirigées vers la même région, créant un déséquilibre temporaire de charge.

Ce partitionnement par plages de clés (range partitioning) diffère fondamentalement du consistant hashing utilisé dans les DHT. Là où une DHT répartit les données de manière pseudo-aléatoire afin de garantir un équilibrage probabiliste et une absence de point central, HBase adopte un partitionnement déterministe fondé sur l'ordre des clés.

Gestion des pannes et réaffectation

En cas de défaillance d'un RegionServer, le HBase Master détecte l'anomalie via Apache ZooKeeper et réassigne les régions concernées à d'autres serveurs actifs.

Grâce au WAL et à la persistance sur HDFS, les données peuvent être reconstruites sans perte. Ce mécanisme de réaffectation centralisée contraste avec l'auto-réorganisation progressive des DHT, où la responsabilité des données est redistribuée de manière distribuée et incrémentale.

1.2.4 Avantages et limites

Cette section analyse les principaux atouts et contraintes de Apache HBase, en lien avec les choix architecturaux précédemment décrits.

Avantages

1. Cohérence forte

L'un des principaux avantages de HBase réside dans sa cohérence forte au niveau de la ligne.

Concrètement, lorsqu'une donnée est écrite avec succès, toute lecture ultérieure renvoie la version la plus récente. Cette propriété est essentielle pour les applications nécessitant une vision fiable et à jour des données, notamment dans des contextes analytiques ou transactionnels.

2. Performances accès séquentiels

Le partitionnement par plages de clés constitue un autre atout majeur. Les lignes étant stockées selon

l'ordre lexicographique des row keys, HBase offre de très bonnes performances pour les requêtes par intervalle, les scans séquentiels et les analyses chronologiques.

Cette organisation rend le système particulièrement adapté aux traitements massifs de données temporelles ou structurées, dans lesquels l'ordre des enregistrements joue un rôle central.

3. Scalabilité horizontale maîtrisée

Grâce au mécanisme de region splitting et à l'ajout dynamique de RegionServers, HBase permet une scalabilité horizontale efficace. L'augmentation du volume de données peut être absorbée par l'ajout de nouveaux nœuds sans modification majeure de l'architecture.

Limites

1. Sensibilité au choix des clés et data skew

Le principal point faible de Apache HBase réside dans sa dépendance au schéma de clés.

Le partitionnement par plages implique que la distribution des données dépend directement de l'ordre lexicographique des row keys. Si celles-ci sont mal conçues — par exemple strictement croissantes — un phénomène de hotspot peut apparaître : une seule région reçoit la majorité des écritures, créant un déséquilibre de charge temporaire.

Ce phénomène constitue une forme de data skew, c'est-à-dire un déséquilibre dans la répartition des données ou des requêtes entre les nœuds d'un système distribué. Dans le cas de HBase, ce déséquilibre peut être :

un storage skew, si certaines régions stockent significativement plus de données ;

un access skew, si certaines régions reçoivent une proportion disproportionnée des requêtes.

2. Complexité opérationnelle

HBase est un système riche mais complexe à administrer. Il dépend de plusieurs composants de l'écosystème Hadoop, notamment HDFS et Apache ZooKeeper.

La gestion du cluster, le réglage des paramètres de performance, la surveillance des régions et l'optimisation du schéma de données exigent une expertise technique significative

1.3 Conclusion et justification du choix architectural

L'analyse précédente a mis en évidence deux paradigmes distincts du stockage distribué : l'approche pair-à-pair structurée incarnée par les DHT, et l'approche hiérarchisée représentée par Apache HBase.

Ces deux architectures répondent à une problématique commune : la distribution de données à grande échelle mais s'appuient sur des hypothèses et des mécanismes fondamentalement différents.

Les DHT reposent sur une décentralisation forte à savoir l'absence de nœud maître, un routage distribué, un hachage cohérent assurant une répartition pseudo-aléatoire, et une auto-organisation dynamique du réseau.

Chaque nœud participe activement au routage et les données sont réparties grâce à un mécanisme de hachage, ce qui permet un bon équilibrage automatique et une adaptation progressive aux variations du système.

À l'inverse, HBase adopte une architecture hiérarchisée à savoir un partitionnement déterministe par plages de clés, une coordination centralisée via un master, une persistance forte reposant sur Hadoop

Distributed File System (HDFS), et une cohérence forte au niveau des lignes.

Les données sont réparties selon des plages de clés et leur gestion est coordonnée. Cette organisation permet un contrôle précis des performances et une bonne prise en charge des requêtes séquentielles, mais suppose un environnement maîtrisé et relativement stable.

Critère d'évaluation : gestion du data skew

Un critère déterminant dans l'évaluation de ces architectures concerne la gestion du data skew, c'est-à-dire le déséquilibre dans la répartition des données ou des requêtes entre les nœuds d'un système distribué.

Dans une architecture à partitionnement par plages, comme HBase, la distribution dépend directement du schéma de clés. Une mauvaise conception peut engendrer des phénomènes de hotspot, conduisant à un déséquilibre significatif de charge (storage skew ou access skew).

À l'inverse, les DHT utilisent un mécanisme de hachage cohérent produisant une distribution pseudo-aléatoire des identifiants. Ce choix réduit structurellement le risque de déséquilibre de stockage et favorise un équilibrage plus homogène sans configuration préalable complexe.

Ainsi, du point de vue de la robustesse face au data skew, l'architecture DHT présente un avantage structurel dans des environnements dynamiques.

Motivation du choix

::

Dans le cadre de notre projet, l'objectif principal est d'implémenter un système pleinement décentralisé, organisé sous forme d'anneau logique. Cette orientation met l'accent sur : la compréhension des mécanismes de routage distribué, l'auto-organisation des nœuds, la gestion dynamique des entrées et sorties dans le réseau, et l'absence de coordination centrale.

De ce point de vue, l'architecture des DHT apparaît particulièrement pertinente. Elle permet d'explorer en profondeur les problématiques fondamentales des systèmes distribués : lookup, maintenance de la structure, tolérance aux pannes, équilibrage probabiliste, et complexité logarithmique du routage.

À l'inverse, une implémentation inspirée de HBase impliquerait la mise en place d'une infrastructure hiérarchisée complexe (gestion d'un master, coordination externe, persistance distribuée), ce qui déplacerait l'intérêt du projet vers des problématiques d'ingénierie de cluster plutôt que vers les mécanismes distribués eux-mêmes.

Conclusion du choix

Ainsi, bien que HBase offre des garanties fortes en matière de cohérence et de gestion structurée des données, l'approche DHT est plus adaptée aux objectifs pédagogiques et expérimentaux du projet. Le choix d'une architecture en anneau décentralisée permet une meilleure exploration des algorithmes distribués, une mise en œuvre plus conceptuellement cohérente avec les principes du pair-à-pair, et une étude approfondie des propriétés émergentes d'un système sans coordination centrale.

En conséquence, nous retenons l'architecture DHT comme fondement de la suite du projet.

2 Méthode de répartition des données


2.1 Motivation et définition de la répartition des données

Avec l'augmentation continue du volume de données et du nombre d'utilisateurs, les architectures de stockage centralisées atteignent rapidement leurs limites. Une base de données unique n'a plus la ca-

pacité de contenir toute ces données et constitue un point de défaillance susceptible de compromettre la disponibilité du système.



Une solution pour pallier à ces limitations consiste à répartir les données et les requêtes sur plusieurs bases de données, afin de distribuer la charge de stockage et de traitement, et d'éviter la surcharge d'une base de données unique.



Toutefois, cette distribution soulève un problème fondamental : il devient nécessaire de déterminer de manière systématique sur quelle base de données une donnée doit être stockée et comment la retrouver efficacement. C'est pour répondre à cette problématique que les méthodes de répartition des données (data partitioning ou data sharding) ont été introduites. Elles définissent les règles de placement des données ce qui impacte directement les performances et l'équilibrage de charge. Ces méthodes de répartitions des données impactent également l'évolution du système dans le temps, c'est-à-dire lors de l'ajout ou le retrait d'une base de données.

2.2 Les différentes méthodes de répartitions des données

Après avoir montré la nécessité de répartir les données dans un système distribué, la première question qu'on se pose : comment associer chaque donnée à une base de données ?

Différentes méthodes de répartition des données permettent d'associer une clé à une base de données dans un système distribué.

Dans les exemples suivant nous allons utiliser le termes nœud qui fait référence à une instance base de données et le terme évènement qui fait référence à une donnée.

2.2.1 hachage classique

Principe général du hachage classique

Une première approche naïve appelée hachage classique (naive hashing ou modulo hashing) consiste à utiliser une fonction de hachage afin de faire la correspondance entre la clé d'une donnée et la base de données dans laquelle nous allons la stocker.


Association d'une clé à un nœud

Cette méthode repose sur les étapes suivantes :

1. Prendre l'id de l'événement et l'exécuter via une fonction de hachage, qui le convertit en nombre
2. Prendre ce nombre et effectuer l'opération modulo (%) avec le nombre de base de données.
3. Le résultat nous indique quelle base de données doit stocker cet événement.

La formule serait donc :

$$\text{database_id} = \text{hash}(\text{event_id}) \bmod \text{number_of_databases}$$



Pour un exemple concret avec 3 bases de données :

Event #1234 → $\text{hash}(1234) \% 3 = 1 \rightarrow \text{Database 2}$

Event #5678 → $\text{hash}(5678) \% 3 = 0 \rightarrow \text{Database 1}$

Event #9012 → $\text{hash}(9012) \% 3 = 2 \rightarrow \text{Database 3}$

Ainsi, chaque clé est associée à une base de données unique, ce qui permet de retrouver l'emplacement d'une donnée à partir de sa clé.

Limite du hachage classique

Le premier problème survient lorsque l'on souhaite ajouter une nouvelle instance de base de données. La première solution à laquelle on pourrait penser consisterait à exécuter l'opération modulo avec 4 au lieu de 3 (Par rapport à l'exemple précédent).

$$\text{database_id} = \text{hash}(\text{event_id}) \% 4$$

La modification du nombre total de bases de données a non seulement affecté les données destinées à la nouvelle instance, mais a également entraîné une modification de la base de données associée à chaque événement précédemment stocké.

En effet, si on reprend un des exemples précédents :


Event #1234 → $\text{hash}(1234) \% 3 = 1 \rightarrow \text{Database 2}$ $\text{hash}(1234) \% 4 = 0 \rightarrow \text{Database 1}$

L'événement n° 1234 était mappé à la base de données 2, mais avec l'ajout de la nouvelle base de données, ces données doivent donc être déplacées vers la base de données 1.



L'ajout d'une ou plusieurs bases de données entraîne donc une redistribution dans toutes les instances de base de données, ce qui provoque un mouvement massif de données inutiles. Ce mouvement massif cause d'énormes pics de charge de base de données et impact directement les utilisateurs. En effet, les utilisateurs ne pourront pas accéder à leur donnée ou auront un temps de réponse lent.

Un autre problème avec le hachage modulo simple réside dans le retrait d'une base de données. Supposons qu'une base de données soit tombée en panne. Il est nécessaire de redistribuer les données qui étaient dans la base de données tombée en panne vers les autres bases de données encore actives. Etant donné que le nombre de base de données actives diminue, le calcul pour trouver où ranger une donnée sera modifié. De ce fait, les données présentes dans les bases de données encore actives risquent d'être redistribuées vers d'autres instances de base de données.



Ces limitations montrent que le hachage modulo classique n'est pas adapté aux systèmes distribués dynamiques, où les bases de données peuvent être ajoutées ou retirées fréquemment.

2.2.2 Hachage cohérent (Consistent Hashing)

Principe général du consistent Hashing

Le consistent Hashing a été introduit pour résoudre le problème de la redistribution des données lors de l'ajout ou de la suppression d'une instance dans un système distribué. Le principe est d'organiser à la fois les données et les bases de données dans un espace circulaire appelé « anneau de hachage ».

Dans cet anneau, les clés et les nœuds sont positionnés en utilisant la même fonction de hachage. Chaque base de données se voit attribuer une position sur l'anneau, et chaque donnée est également positionnée sur cet anneau en fonction du résultat de sa fonction de hachage.

Association d'une clé à un nœud


Cette méthode repose sur les étapes suivantes :

1. On réalise d'abord un anneau de hachage avec un nombre fixe de points.
2. On positionne les bases de données sur l'anneau en appliquant la fonction de hachage à leur identifiant.
3. Pour trouver sur quelle base de données une donnée doit être stockée, on hache d'abord l'ID de la donnée comme avec le hachage classique.
4. On se déplace ensuite dans le sens des aiguilles d'une montre sur l'anneau jusqu'à rencontrer le premier nœud.
5. Ce nœud va stocker de la donnée.

Par exemple :

Pour un nombre fixe de points égal à 90, 3 bases de données positionnées aux points 20, 50 et 80.

Si nous avons un $\text{hash}(\text{id_data}) = 32$, nous nous déplaçons dans le sens des aiguilles d'une montre pour trouver la première instance de base de données. Cette instance sera la base de données 2 (Node B) située au point 50.



Ajout d'une nouvelle base de données

Lorsqu'on ajoute une nouvelle base de données, seules les données qui se situent entre sa nouvelle position et la base de données précédente doivent être déplacées.


Par exemple :

Pour un nombre fixe de points égal à 100, 4 bases de données positionnées aux points 0, 25, 50 et 75.

Si nous ajoutons une cinquième base de données à la position 90 sur notre anneau :

- Seules les données qui se hachent vers des positions comprises entre 75 et 90 doivent désormais être stockées dans la base de données 5.

- Toutes les autres données restent dans leur base de données respective.



Hash Ring with DB5 added

Contrairement au hachage modulo classique, seule une petite portion des données est redistribuée.


Suppression d'une base de données

En reprenant l'exemple initial :

Pour un nombre fixe de points égal à 100, 4 bases de données positionnées aux points 0, 25, 50 et 75.

Supposons que la base de données numéro 2 située à la position 25 rencontre une défaillance.

- Seules les données mappées sur la base de données 2 doivent être déplacées.
- Le déplacement se fait dans le sens des aiguilles d'une montre. Elles seront donc mappées à la base de données 3 située à la position 50.
- Toutes les autres données restent dans leur base de données respective.



Le consistent hashing permet ainsi de résoudre les principales limites du hachage classique en réduisant drastiquement le nombre de données redistribuées lors des changements de topologie (ajout ou retrait de base de données).


Cependant, il reste encore un problème. En effet, dans notre exemple ci-dessus où nous avons supprimé la base de données 2, nous avons dû déplacer toutes les données stockées dans la base de données 2 vers la base de données 3, ce qui peut entraîner une surcharge locale. Notre objectif serait de répartir de manière équitable les données lors de la suppression d'une base de données.

Optimisation : Nœuds Virtuels

Pour résoudre ce problème, une des solutions serait d'utiliser des « nœuds virtuels ». Au lieu de mettre chaque base de données en un seul point sur l'anneau, nous la divisons en plusieurs points en hachant différentes variantes du nom de la base de données.

Par exemple :

« DB1 » sera divisé en « DB1-vn1 », « DB1-vn2 », « DB1-vn3 » et « DB1-vn4 » qui seront respectivement aux positions 0, 20, 35, 65, 80. C'est le même principe pour les autres bases de données.



Nous pouvons observer sur la figure ci-dessus que les nœuds virtuelles sont mélangés autour de l'anneau. Supposons que la bases de données numéro 2 rencontre une défaillance :

- Les données mappées sur « DB2-vn1 » seront stockées dans la base de données 1
- Les données mappées sur « DB2-vn2 » seront stockées dans la base de données 3
- Les données mappées sur « DB2-vn3 » seront stockées dans la base de données 4
- Et ainsi de suite

La charge de la base de données supprimé est donc répartie de manière beaucoup plus homogène dans toute les bases de données actives.

2.3 Conclusion sur les méthodes de répartitions des données

Les méthodes de répartition des données sont donc indispensables dans les systèmes distribués. En effet, elles déterminent la manière dont les données sont réparties entre les bases de données. Le hachage classique est une solution simple, mais peu adaptée lors de l'ajout ou du retrait d'une ou plusieurs bases de données, en raison des redistributions massives qu'il engendre. Le consistant hashing permet de corriger ces limitations en réduisant les déplacements de données. Une des optimisations du consistant hashing repose sur l'utilisation de nœuds virtuels, permettant d'améliorer l'équilibrage de charge entre les nœuds lors du retrait d'une base de données.

3 Chord

Chord est un protocole de *lookup* distribué qui répond à un problème fondamental : localiser efficacement le nœud stockant une donnée particulière. Alors que de nombreux systèmes *peer-to-peer* offrent des fonctionnalités complexes comme l'anonymat ou le stockage redondant, Chord se concentre exclusivement sur une opération centrale : le *mapping* d'une *key* vers un nœud.

3.1 Design du système et philosophie

Chord est conçu comme une bibliothèque liée aux applications clientes et serveurs. Il répond à cinq défis critiques des systèmes *peer-to-peer* (P2P) :

1. **Load Balance** : Chord agit comme une fonction de *hash* distribuée, répartissant les *keys* uniformément pour éviter qu'un seul nœud ne soit submergé.

2. **Decentralisation** : Aucun nœud n'est plus important qu'un autre, ce qui élimine les *single points of failure* tels que ceux rencontrés dans Napster.
3. **Scalability** : Le coût du *lookup* croît selon le logarithme du nombre de nœuds, rendant possible l'exploitation de systèmes impliquant des millions de participants.
4. **Availability** : Le système s'ajuste automatiquement aux *joins* et aux *failures*, garantissant que le nœud responsable soit toujours localisé.
5. **Flexible Naming** : Chord utilise un *flat key space*, offrant aux applications une liberté totale quant à la manière de lier leurs noms internes aux *keys* de Chord.

3.2 Consistent Hashing et l'Identifiant Circle

Chord utilise une variante du *consistent hashing* pour assigner les *keys* aux nœuds.

Les nœuds ainsi que les *keys* reçoivent un **identifiant** de m bits via une fonction de *hash* de base telle que SHA-1. L'ID d'un nœud est dérivé de son adresse IP, tandis que l'ID d'une *key* est le *hash* de la donnée elle-même.

Les identifiants sont disposés sur un cercle modulo 2^m appelé **chord ring**. Une *key* k est assignée au premier nœud dont l'identifiant est égal ou supérieur à k dans le sens des aiguilles d'une montre. Ce nœud est appelé le *successor* de la *key* k .

3.3 Localisation de clés scalable : Finger Tables

Pour éviter l'inefficacité d'un parcours linéaire du cercle, Chord maintient une table de routage appelée **finger table**.

Chaque nœud n maintient jusqu'à m entrées. La $i^{\text{ème}}$ entrée pointe vers le premier nœud qui succède à n d'au moins 2^{i-1} .

Approche par Binary Search : Cette structure permet à un nœud de stocker davantage d'informations sur les nœuds qui le suivent de près et moins sur ceux qui sont plus éloignés.

Performance : Chaque *lookup* réduit de moitié la distance vers la cible, garantissant que la destination est atteinte en $O(\log N)$ *hops*.

Les nœuds proches d'une *key* disposent d'informations de type "*fine-grained*", tandis que les nœuds plus éloignés permettent des "*long jumps*" à travers le réseau pour accélérer la recherche.

3.4 Théorèmes

L'article présente 8 théorèmes servant à justifier l'usage du *consistent hashing* et de la structure de la **finger table**.

Théorème 1

Pour tout ensemble de N nœuds et K keys, avec une probabilité élevée : chaque nœud est responsable d'au plus $(1 + \epsilon)K/N$ keys. Lorsqu'un $(N + 1)^{\text{ème}}$ nœud rejoint ou quitte le réseau, seules $O(K/N)$ keys sont déplacées.

Ce premier théorème traite de l'efficacité avec laquelle Chord répartit les données sur le réseau, réalisant un "*natural load balance*". Il garantit qu'aucune machine ne devienne un goulot d'étranglement.

Théorème 2

Avec une probabilité élevée, le nombre de nœuds devant être contactés pour trouver un successor dans un réseau de N nœuds est en $O(\log N)$.

Ce théorème démontre l'efficacité des *lookups*, même dans des systèmes comptant des millions de nœuds. Il justifie la structure de la **finger table**, où chaque *hop* est conçu pour réduire de moitié la distance vers l'ID cible.

Théorème 3

Avec une probabilité élevée, tout nœud rejoignant ou quittant un réseau Chord de N nœuds utilisera $O(\log^2 N)$ messages pour rétablir les finger tables et les invariants de routage.

Le troisième théorème quantifie le coût du maintien de la structure du réseau lors de l'arrivée ou du départ de participants. Il permet aux développeurs d'estimer le "*management overhead*" du système. Il montre que bien qu'un *join* soit plus coûteux qu'un simple *lookup*, il reste très performant à mesure que le réseau croît.

Théorème 4

Dès qu'un nœud peut résoudre avec succès une requête donnée, il sera toujours en mesure de le faire à l'avenir.

Cette propriété garantit qu'une fois que le réseau a atteint un état où un chemin vers une *key* existe, les routines de maintenance du protocole ne briseront pas cette connectivité.

Théorème 5

Passé un certain délai après le dernier join, tous les successor pointers seront corrects.

Le protocole *stabilize* garantit la convergence, ramenant ainsi le réseau vers un état de cercle parfait une fois que le "*churn*" des nœuds entrants s'arrête.

Théorème 6

Si nous prenons un réseau stable de N nœuds, et qu'un autre ensemble allant jusqu'à N nœuds rejoint le réseau sans finger pointers (mais avec des successor pointers corrects), alors les lookups prendront toujours un temps en $O(\log N)$ avec une probabilité élevée.

Cela prouve que Chord est extrêmement résilient lors de phases de croissance. Même si un nombre massif de nouveaux nœuds rejoint le réseau sans avoir encore construit leurs **finger tables**, l'infrastructure existante garantit que la vitesse de recherche ne se dégrade pas.

Théorème 7

Si nous utilisons une successor list de longueur $r = O(\log N)$ dans un réseau initialement stable, et que chaque nœud échoue avec une probabilité de $1/2$, alors avec une probabilité élevée `find_successor` renvoie le successor vivant le plus proche de la key demandée.

Ce théorème valide le mécanisme de **Successor List**. Il prouve qu'avec seulement une quantité logarithmique de redondance, le système peut localiser les données de manière fiable, même si la moitié des machines du réseau disparaissent simultanément.

Théorème 8

Si nous utilisons une successor list de longueur $r = O(\log N)$ dans un réseau initialement stable, et que chaque nœud échoue avec une probabilité de $1/2$, alors le temps attendu pour exécuter `find_successor` dans le réseau défaillant est en $O(\log N)$.

Il s'agit du pendant de performance du Théorème 7. Il garantit que non seulement la recherche trouvera le nœud correct après une défaillance de 50%, mais qu'elle le fera avec la même efficacité logarithmique.

3.5 Algorithmes des nœuds

1. L'algorithme de Successor Resolution

Le cœur de l'efficacité de Chord réside dans la fonction `find_successor`. Elle utilise la **finger table** pour effectuer des bonds exponentiels vers l'ID cible.

Algorithm: `Node.find_successor(id)`

```

1: if  $id \in (\text{node}, \text{successor}]$  then
2:   return successor
3: else
4:    $n' = \text{closest\_preceding\_node}(id)$ 
5:   return  $n'.\text{find\_successor}(id)$ 
6: end if
```

Pour trouver le nœud précédent le plus proche, le système itère à travers la **finger table**, du saut le plus grand vers le plus petit :

Algorithm: Node.closest_preceding_node(*id*)

```

1: for  $i = m$  downto 1 do
2:   if  $\text{finger}[i].\text{node} \in (\text{node}, id)$  then
3:     return  $\text{finger}[i].\text{node}$ 
4:   end if
5: end for
6: return node

```

2. Maintenance dynamique du ring : Joining et Stabilisation

Lorsqu'un nœud rejoint le réseau, il n'a besoin de connaître qu'un seul nœud existant pour s'intégrer au cercle. La fonction `stabilize` est exécutée périodiquement pour vérifier le *successor* et l'informer de l'existence du nœud.

Algorithm: Node.join(*n'*)

```

1: predecessor = nil
2: successor =  $n'.\text{find\_successor}(\text{node})$ 

```

Algorithm: Node.stabilize()

```

1:  $x = \text{successor.predecessor}$ 
2: if  $x \in (\text{node}, \text{successor})$  then
3:   successor =  $x$ 
4: end if
5: successor.notify(node)

```

3. Résilience : Le mécanisme de Successor List

Pour gérer le "*churn*" des nœuds tombant en panne sans préavis, chaque nœud maintient une liste de r *successors*. Cela garantit que si le *successor* primaire échoue, le nœud peut toujours router vers le prochain nœud actif disponible dans la liste.

Algorithm: Node.check_predecessor()

```

1: if (predecessor has failed) then
2:   predecessor = nil
3: end if

```

Algorithm: Node.handle_successor_failure()

```

1: for each  $s \in \text{successor\_list}$  do
2:   if  $s$  is alive then
3:     successor =  $s$ 
4:     break
5:   end if
6: end for

```

3.6 Algorithmes de la Finger Table

1. Calcul des entrées de la Finger Table

Chaque nœud n maintient une table de routage de m entrées. La $i^{\text{ème}}$ entrée est définie comme le premier nœud qui succède au point $n + 2^{i-1}$ sur le cercle d'identifiants.

$$\begin{aligned}\text{finger}[i].\text{start} &= (n + 2^{i-1}) \pmod{2^m}, \quad 1 \leq i \leq m \\ \text{finger}[i].\text{node} &= \text{find_successor}(\text{finger}[i].\text{start})\end{aligned}$$

2. Initialisation de la Finger Table

Lorsqu'un nouveau nœud rejoint le réseau, il doit renseigner sa **finger table**. Alors qu'une approche naïve consisterait à appeler `find_successor` m fois, le protocole utilise souvent des nœuds existants pour fournir des "*hints*", réduisant ainsi la complexité de l'initialisation.

Algorithm: Node.init_finger_table(n')

```

1: finger[1].node = n'.find_successor(finger[1].start)
2: predecessor = successor.predecessor
3: successor.predecessor = node
4: for i = 1 to m - 1 do
5:   if finger[i + 1].start ∈ [node, finger[i].node] then
6:     finger[i + 1].node = finger[i].node
7:   else
8:     finger[i + 1].node = n'.find_successor(finger[i + 1].start)
9:   end if
10: end for

```

3. Maintenance proactive de la table

Le réseau étant dynamique, les entrées des doigts peuvent devenir "*stale*" lors de l'arrivée ou du départ de nœuds. La routine `fix_fingers` est exécutée périodiquement pour rafraîchir une entrée aléatoire, garantissant que les informations de routage demeurent *eventually consistent*.

Algorithm: Node.fix_fingers()

```

1: i = random index ∈ [1, m]
2: finger[i].node = find_successor(finger[i].start)

```

4. Mise à jour des autres nœuds

Lorsqu'un nouveau nœud n rejoint le réseau, il peut devenir le $i^{\text{ème}}$ doigt de plusieurs nœuds existants. La fonction `update_others` identifie ces nœuds et les force à mettre à jour leurs tables pour refléter l'arrivée de n .

Algorithm: Node.update_others()

```

1: for  $i = 1$  to  $m$  do
2:    $p = \text{find\_predecessor}(\text{node} - 2^{i-1})$ 
3:    $p.\text{update\_finger\_table}(\text{node}, i)$ 
4: end for

```

Algorithm: p.update_finger_table(s, i)

```

1: if  $s \in [\text{node}, \text{finger}[i].\text{node})$  then
2:    $\text{finger}[i].\text{node} = s$ 
3:    $p = \text{predecessor}$ 
4:    $p.\text{update\_finger\_table}(s, i)$ 
5: end if

```

4 Pastry

Pastry est une infrastructure distribuée de localisation d'objets et de routage destinée aux systèmes pair-à-pair (P2P) à grande échelle. Elle repose sur une table de hachage distribuée (DHT), comparable à Chord, et fonctionne au-dessus d'Internet via un réseau overlay. Les nœuds logiques de Pastry ne correspondent pas nécessairement à la topologie physique du réseau IP, mais forment une structure virtuelle organisée selon l'espace des identifiants.

L'objectif fondamental de Pastry est d'acheminer efficacement un message associé à une clé donnée vers le nœud dont l'identifiant est numériquement le plus proche de cette clé. À l'instar de Chord, Pastry résout le problème du *key-based routing*, mais adopte une approche différente fondée sur un routage par préfixes plutôt que sur une structure strictement circulaire.

4.1 Architecture générale

La conception de Pastry repose sur plusieurs principes structurants :

1. Décentralisation

Aucun nœud ne possède de rôle central. Chaque participant maintient localement ses structures de routage, ce qui supprime tout point unique de défaillance.

2. Scalabilité logarithmique

Le routage s'effectue en $O(\log N)$ sauts en moyenne, où N est le nombre de nœuds du système, ce qui garantit le passage à grande échelle.

3. Auto-organisation

Le protocole s'adapte dynamiquement aux arrivées et aux départs de nœuds (*churn*) par la mise à jour progressive des structures de routage.

4. Localité réseau

Lorsque plusieurs nœuds satisfont une contrainte de routage, Pastry privilégie celui qui est le plus proche selon une métrique réseau, réduisant ainsi la latence réelle des communications.

4.2 Identifiants et espace de clés

Chaque nœud Pastry possède un identifiant unique, appelé *nodeId*, généralement codé sur 128 bits et dérivé d'une fonction de hachage cryptographique. De même, chaque message ou clé à router reçoit un identifiant correspondant dans le même espace.

L'espace d'identifiants est organisé en base 2^b , où b est un paramètre de configuration influençant la taille des tables de routage. Le routage s'effectue en recherchant le nœud actif dont le *nodeId* est numériquement le plus proche de l'identifiant cible.

Contrairement à Chord, qui dispose d'un anneau strictement circulaire, Pastry utilise un routage par préfixes, où la distance est mesurée par la longueur du préfixe commun entre identifiants.

4.3 Structures de routage

Chaque nœud Pastry maintient trois structures principales : la *Routing Table*, le *Leaf Set* et le *Neighbor Set*.

4.3.1 1. Routing Table

Organisée par préfixes d'identifiants, elle contient des pointeurs vers des nœuds partageant des préfixes communs avec le *nodeId* courant. Cette structure permet de faire des sauts logarithmiques vers la destination, rapprochant le message à chaque étape.

Cette structure est analogue aux *Finger Tables* de Chord, mais basée sur des préfixes plutôt que sur des puissances de 2.

4.3.2 2. Leaf Set (ensemble des feuilles)

Il regroupe les nœuds immédiatement supérieurs et inférieurs au *nodeId*. Il assure le routage correct pour les clés proches et fournit des alternatives en cas de défaillance de certains nœuds.

4.3.3 3. Neighbor Set (ensemble des voisins)

Il contient des nœuds physiquement proches selon la topologie réseau, indépendamment des identifiants. Il est utilisé pour optimiser la latence des communications et améliorer la localité réelle du routage.

4.4 Processus de routage

Le routage dans Pastry s'effectue en rapprochant progressivement le message de son *nodeId* cible grâce aux structures précédentes :

1. **Vérification du Leaf Set** : si la clé cible se trouve dans l'intervalle couvert, le message est envoyé au nœud le plus proche numériquement.
2. **Utilisation de la Routing Table** : si la clé n'est pas dans le Leaf Set, le message est transmis à un nœud partageant un préfixe plus long avec la clé.
3. **Sélection par proximité physique** : si aucune entrée n'est disponible ou valide, un nœud du Leaf Set numériquement plus proche est choisi, en prenant en compte la distance réseau.

À chaque étape, le message progresse vers un nœud plus proche de la destination, ce qui garantit la convergence du routage en $O(\log N)$ sauts en moyenne pour N nœuds actifs.

4.5 Algorithmes des nœuds et maintenance

Chaque nœud Pastry exécute des algorithmes pour intégrer de nouveaux nœuds, maintenir les structures de routage et gérer les défaillances.

1. Intégration d'un nouveau nœud (*join*)

- Un nœud entrant contacte un nœud existant pour s'intégrer au réseau.
- Les structures de routage (*Routing Table*, *Leaf Set*, *Neighbor Set*) sont initialisées progressivement grâce aux informations des nœuds voisins.

2. Maintenance dynamique (*stabilize* et *mise à jour du routage*)

- Les entrées de la *Routing Table* sont périodiquement mises à jour pour refléter les départs ou arrivées de nœuds.
- Le *Leaf Set* et le *Neighbor Set* sont également ajustés pour maintenir la cohérence et la résilience locale.

3. Tolérance aux pannes

- En cas de défaillance d'un nœud, les messages sont redirigés vers le nœud le plus proche dans le *Leaf Set* ou via la *Routing Table*.
- Cette redondance garantit que le routage reste correct et efficace même avec un nombre important de nœuds défaillants.

5 Architecture du système et cycle de vie d'une requête

5.1 Choix architecturaux et problématique

Dans le cadre de notre projet, nous avons choisi d'implémenter une architecture de stockage distribuée reposant sur des protocoles de type Distributed Hash Table (DHT), et plus précisément sur Chord et Pastry. Ces deux protocoles partagent un objectif commun : organiser un ensemble de nœuds distribués de manière totalement décentralisée afin d'assurer le stockage et la localisation efficace de données dans un espace d'identifiants partagé.

Avant d'implémenter ces protocoles, il est essentiel de comprendre précisément l'architecture que nous allons construire ainsi que le protocole applicatif qui s'appuiera dessus. Autrement dit, nous devons être capables de répondre aux questions suivantes :

- À quel nœud une requête est-elle envoyée initialement ?
- Comment est déterminé le nœud responsable d'une donnée ?
- Comment les nœuds communiquent-ils entre eux ?
- Que se passe-t-il concrètement lors d'une opération élémentaire telle que PUT ou GET ?
- Quel est le cycle de vie complet d'une requête ?

Dans cette première partie, nous détaillons l'architecture retenue pour Chord, en analysant précisément la circulation des messages, la responsabilité des nœuds et le traitement des requêtes. La même démarche sera ensuite appliquée à Pastry.

5.1.1 Architecture générale basée sur Chord

Résumons l'architecture Chord vue précédemment en indiquant les différentes variables qui nous seront indispensables lors de son implémentation. L'architecture Chord repose sur un espace d'identifiants circulaire de taille 2^m . Cet espace est partagé à la fois par les nœuds du système et par les clés des données stockées. Chaque nœud reçoit un identifiant unique calculé via une fonction de hachage, et se positionne sur un anneau logique selon cet identifiant.

Le principe fondamental de Chord est le suivant : une clé est stockée sur le premier nœud dont l'identifiant est supérieur ou égal à l'identifiant de la clé dans le sens des aiguilles d'une montre. Ce

nœud est appelé le successeur de la clé. Cette règle garantit un placement déterministe et uniforme des données sans coordination centrale.

Chaque nœud maintient localement plusieurs structures essentielles :

- son identifiant unique,
- un pointeur vers son successeur,
- un pointeur vers son prédécesseur,
- une table de routage appelée finger table,
- un stockage local des paires (clé, valeur).

La finger table permet d'assurer un routage logarithmique. Chaque entrée de cette table pointe vers un nœud situé exponentiellement plus loin sur l'anneau. Ainsi, lorsqu'un nœud doit localiser le responsable d'une clé, il peut se rapprocher de la destination en un nombre de sauts proportionnel à $O(\log N)$, où N est le nombre total de nœuds.

5.1.2 Couche Overlay et Couche applicative

Il est essentiel, dans notre implémentation, de distinguer clairement deux niveaux fonctionnels qui coexistent au sein de chaque nœud.

Le premier niveau correspond à la couche overlay, c'est-à-dire le protocole Chord lui-même. Cette couche est responsable de l'organisation logique du réseau en anneau, du maintien des pointeurs (successeur, prédécesseur, finger table) et du routage des messages. Son rôle est exclusivement de répondre à la question suivante : quel nœud est responsable d'un identifiant donné ? Autrement dit, Chord assure la localisation distribuée des clés.

Le second niveau correspond à la couche applicative, que nous implémentons au-dessus de Chord. Cette couche gère concrètement le stockage des paires (clé, valeur) sur le nœud responsable. Elle implémente les opérations élémentaires telles que PUT, GET ou DELETE, et décide éventuellement des mécanismes de réplication ou de gestion de la cohérence.

Ainsi, Chord ne stocke pas directement les données : il fournit un mécanisme de routage déterministe permettant d'identifier le bon nœud. La gestion effective des données repose sur la couche applicative locale de chaque nœud.

5.1.3 Cycle de vie d'une requête

Requête PUT

Lorsqu'un client souhaite insérer une donnée via PUT(key, value), la requête est envoyée à un nœud arbitraire du réseau. Ce nœud devient le point d'entrée du système, mais il n'est pas nécessairement responsable de la clé.

Le nœud calcule d'abord l'identifiant associé à la clé en appliquant la fonction de hachage. L'identifiant obtenu est positionné dans le même espace circulaire que les nœuds.

Le nœud exécute alors la procédure `find_successor(id)`. Si l'identifiant appartient à l'intervalle compris entre le nœud courant et son successeur, alors ce successeur est responsable. Sinon, le nœud consulte sa finger table pour déterminer le *closest preceding node*, c'est-à-dire le nœud le plus proche précédant la cible. La requête est alors transmise à ce nœud. Ce processus se répète récursivement jusqu'à atteindre le nœud responsable.

Une fois le nœud responsable localisé, la paire (clé, valeur) est stockée localement. Pour assurer une tolérance aux pannes, cette donnée peut être répliquée sur plusieurs successeurs afin d'assurer une redondance. Une réponse de confirmation est ensuite renvoyée au client.

Requête GET

Le traitement d'une requête GET(key) suit exactement la même logique de routage que PUT. La différence réside uniquement dans l'opération finale.

Après avoir localisé le nœud responsable via `find_successor`, celui-ci consulte son stockage local pour récupérer la valeur associée à la clé. Si la clé est présente, la valeur est renvoyée au client. Sinon, une réponse d'absence est transmise au client.

La latence globale d'une requête GET dépend principalement du nombre de sauts nécessaires pour atteindre le nœud responsable, ce qui reste logarithmique.

Requête DELETE

Le traitement d'une requête DELETE(key) suit le même mécanisme de localisation que les opérations PUT et GET. Le nœud qui reçoit la requête commence par calculer l'identifiant associé à la clé via la fonction de hachage, puis exécute la procédure `find_successor` afin de déterminer le nœud responsable. Une fois ce nœud atteint, la suppression est effectuée localement dans le stockage clé-valeur. Si un mécanisme de réplication est implémenté, la suppression doit également être propagée aux nœuds réplicas afin de maintenir la cohérence du système. Une confirmation est ensuite renvoyée au client. Comme pour les autres opérations, la complexité de la localisation reste logarithmique, et la suppression ne nécessite aucune coordination globale en dehors du routage vers le nœud responsable.

5.1.4 Conclusion sur l'architecture Chord

L'architecture que nous mettons en place repose sur une séparation entre le mécanisme de localisation distribué et la couche applicative de stockage. Cette structuration nous permet de construire un système scalable et entièrement décentralisé, dans lequel chaque nœud participe à la fois au routage et au stockage des données.

Cependant, si l'overlay garantit une localisation efficace des clés, la robustesse réelle du système dépendra des choix que nous ferons au niveau applicatif, notamment en matière de réplication, de gestion des pannes et de cohérence. La stabilité dynamique de l'anneau, en particulier en présence de churn, influencera directement les performances et la fiabilité du système.

Nous considérons ainsi cette architecture comme une base solide et extensible, dont le comportement effectif dépendra de la rigueur de notre implémentation et des mécanismes complémentaires que nous déciderons d'y intégrer.